Le Data Mining

Christopher de Boisvillierrs

2025-03-17

Partie 1: Introduction

📊 Qu'est-ce que le Data Mining ?

📌 Définition : Le **Data Mining**, ou **exploration de données**, est une technique qui permet d'**analyser de grandes quantités de données** afin d'y découvrir des **tendances, des modèles cachés et des relations utiles**.

À quoi ça sert ?

- 🔍 **Trouver des liens** entre différentes données

  Exemple : quels produits sont souvent achetés ensemble ?

- 🚨 **Détecter des anomalies**

  Exemple : repérer une fraude bancaire en analysant des transactions inhabituelles.

- 📁 **Classer des données** en catégories

  Exemple : un email est-il un spam ou non ?

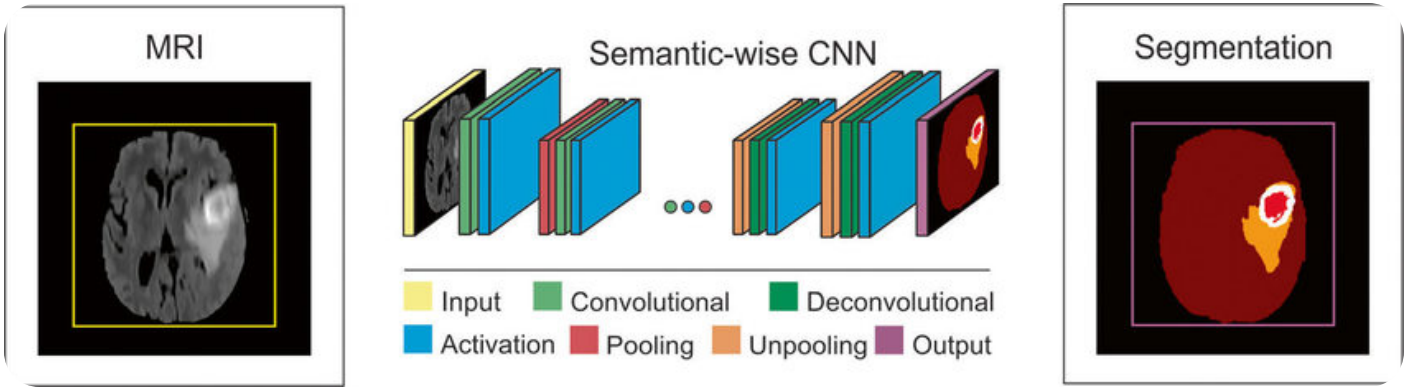
- 📈 **Prédire des valeurs (régression)**

  Exemple : estimer le prix d'une maison en fonction de sa surface.

Des exemples concrets (1/3) ? 🔍 *La tumeur*

- 🏥 **Médecine**

  Détection d'une tumeur chez un patient



Le but du jeu sera de trouver un **LIEN** permettant de différencier des cerveaux sain et d'autres atteints d'une tumeur.

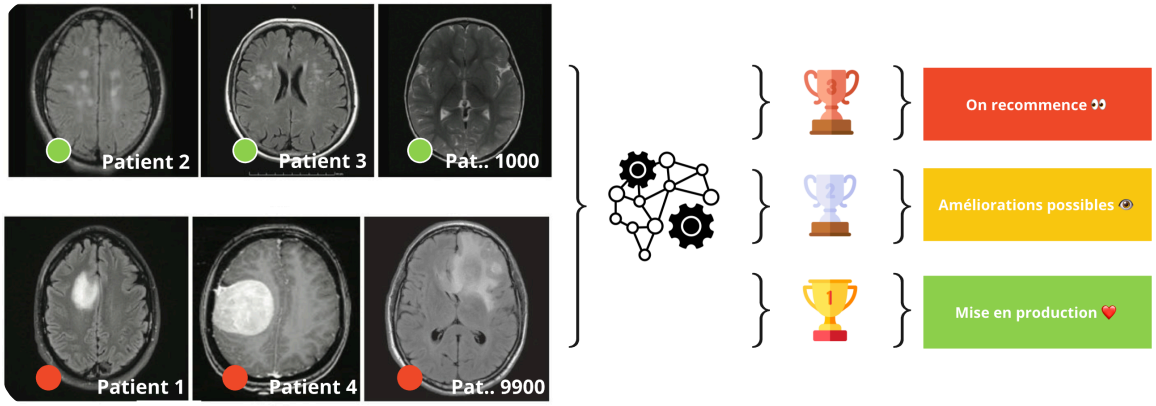
Nous pouvons déja imaginer un **DATASET** qui se presentera de la sorte:

Patient	image	Tumeur détectée (*Classe*)
Patient 1	patient_1.png	Oui
Patient 2	patient_2.png	Non

Des exemples concrets (1/3) ? 🔍 *La tumeur*

La recette pour trouver ce fameux **LIEN** ?

1. **Collecte des données** : collecter des IRM de patients avec et sans tumeurs.
2. **Prétraitement** : nettoyer, *normaliser*, redimensionner les données.
3. **Modélisation** : entraîner un algorithme de *classification* (ex: CNN, Random Forest).
4. **Évaluation** : **mesurer** la **précision**, le **rappel**, la **matrice de confusion**.



Approfondir le sujet : Brain Tumor Classification with CNN using TensorFlow

💡 Question ouverte

Quels autres critères pourraient aider à savoir si le patient à une tumeur ?

Des exemples concrets (2/3) ? 🔍 *Estimation du prix d'un bien immobilier ?*

Imaginons que nous voulons **prédire le prix** d'une maison en fonction de plusieurs critères:

- 🏠 **Surface de la maison (m²)**
- 🚩 **Localisation** (quartier, proximité des écoles, commerces…)
- 🚗 **Nombre de places de parking**
- 🍽️ **Présence d'une piscine**

Problème : Comment trouver un lien entre des données que l'agence possède et le prix d'une maison/appt.

Des exemples concrets (2/3) ? 🔍 *Estimation du prix d'un bien immobilier ?*

Voici le dataset que possède l'agence comme source de données.

Maison ID	Surface (m^2)	Quartier	Parking	Piscine	Prix (*Cible*)
1	120	Centre	1	Oui	350 000
2	80	Banlieue	0	Non	180 000
3	150	Centre	2	Oui	500 000
4	90	Périphérie	1	Non	220 000

Nous souhaitons trouver un lien entre notre dataset et la variable **cible** prix

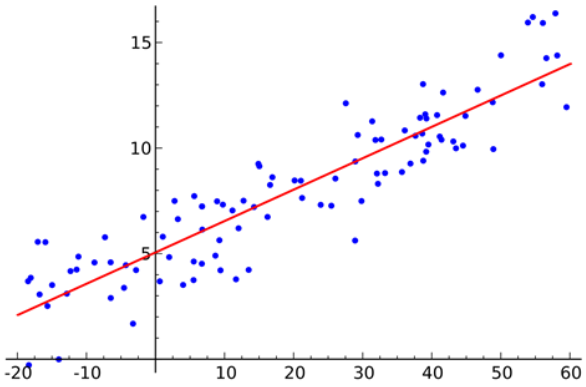
Des exemples concrets (2/3) ? 🔍 *Estimation du prix d'un bien immobilier ?*

La recette pour trouver ce fameux **LIEN** ?

1. **Collecte des données** : Historique des ventes immobilières.
2. **Prétraitement** : Nettoyage des données, transformation des variables catégorielles.
3. **Modélisation** : **Modèle** pour trouver les **facteurs influençant le prix**.
4. **Prédiction** : Estimer le prix d'une nouvelle maison selon ses caractéristiques.
5. **Évaluation** : Vérification avec les indicateurs **MAE, RMSE, R^2**.

Des exemples concrets (2/3) ? 🔍 *Estimation du prix d'un bien immobilier ?*

- **Relation entre surface et prix :**



Impact des caractéristiques :

- Une **maison plus grande** coûte généralement **plus cher**.
- Un **quartier central** augmente la valeur.
- La **présence d'une piscine** ajoute une **valeur significative**.

Conclusion : Grâce au modèle, l'agent immobilier peut **prédire un prix réaliste** pour chaque maison et mieux conseiller ses clients.

💡 Question ouverte

Quels autres critères pourraient influencer le prix d'une maison ?

Des exemples concrets (3/3) ? 🔍 *Classification de patients à risque*

📌 Contexte

Un hôpital souhaite **analyser ses patients** pour mieux comprendre **les facteurs de risque** associés à certaines maladies comme le diabète ou les maladies cardiaques. Cependant, les médecins ne connaissent **pas à l'avance** les catégories de patients à risque.

C'est un problème de **clustering** où nous cherchons à découvrir des groupes naturels dans les données sans avoir d'étiquettes prédéfinies.

Ce **lien** sera notre fonction d'attribution.

💡 **Objectif** : Utiliser un algorithme pour **regrouper automatiquement** les patients en fonction de leurs caractéristiques médicales.

🔍 Collecte de nos données

Nous disposons d'un **dataset médical** contenant plusieurs variables :

Patient	Âge	IMC	Tension	Glycémie	Activité (h/semaine)
Patient 1	65	30	140/90	1.5	0
Patient 2	45	25	120/80	0.9	5
Patient 3	55	32	135/85	1.8	1
Patient 4	38	22	115/75	0.7	7
Patient 5	60	35	145/95	2.0	0.5

📌 **Problème** : Comment sans différentes classe au préalable je peux différencier mes patients ?

🔍 Application d'un algorithme de clustering

🔧 Étapes du clustering :

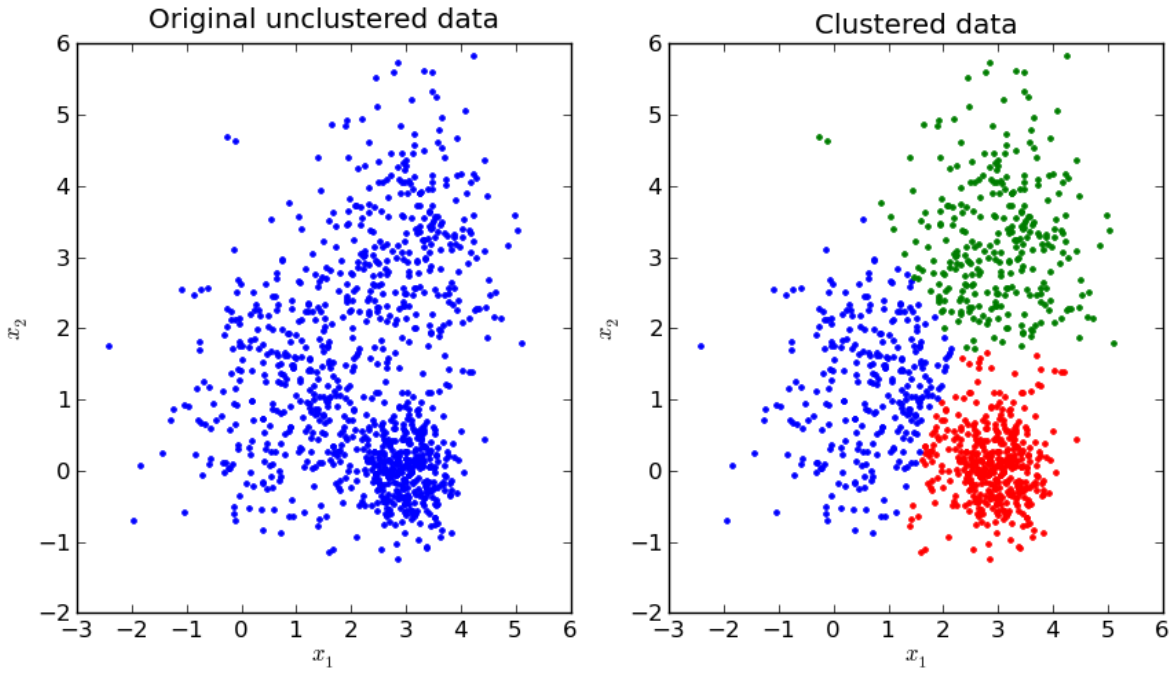
1. **Prétraitement des données** : **Normalisation** des valeurs (âge, IMC, glycémie...).
2. **Estimer un nombre de cluster** : Test avec **K=3**.
3. **Clustering** : Regroupe les patients en fonction de leur **profil médical**.
4. **Analyse des groupes** : Identifier les **facteurs communs** dans chaque groupe.

💡 Résultats et interprétation

Après application **d'un algorithme de clustering**, on obtient **trois groupes distincts** :

Cluster	Profil des patients	Risque médical
Groupe 1	Patients jeunes, activité physique élevée, glycémie normale	**Faible**
Groupe 2	Patients d'âge moyen, IMC modéré, glycémie légèrement élevée	**Moyen**
Groupe 3	Patients âgés, obèses, glycémie élevée, faible activité physique	**Élevé**

Visualisation des clusters :



Conclusion : L'hôpital peut utiliser ces groupes pour **cibler les patients à risque élevé** et leur proposer des **programmes de prévention** adaptés.

💡 Question ouverte

Dans quels autres domaines pourrait-on utiliser du clustering pour regrouper des individus ou objets ?

💡 Question

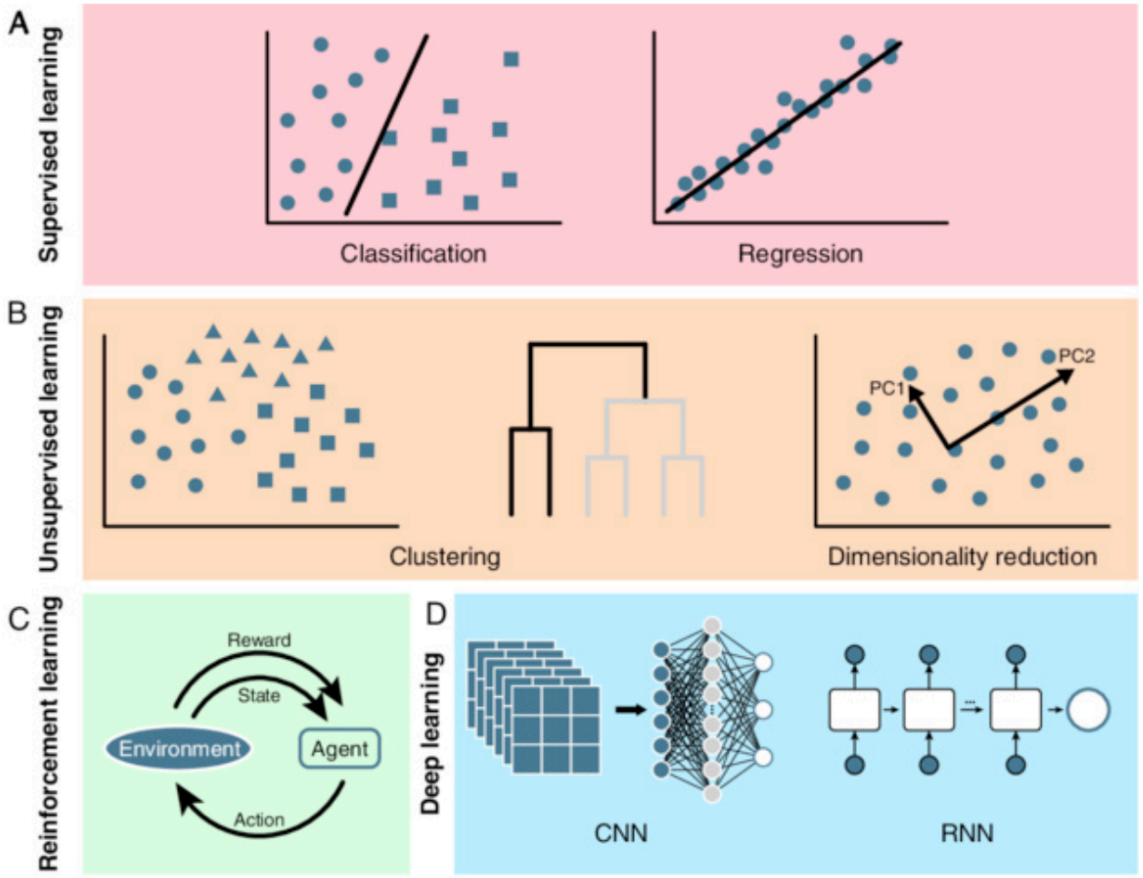
Qu'avez-vous remarqué dans les trois exemples précédents ?

📄 Réponse:

Cas d'étude	Cible	KPI	Type
1	Classe (tumeur ou non)	Rappel,matrice de confusion etc	Supérvisé
2	Prix (valeur numérique)	R^2, mae	Supérvisé
3	Aucune	silhouette	Non Supérvisé

Il éxiste donc des familles d'algorithmes ?

Regardons l'image suivante :



Il éxiste donc des familles d'algorithmes ?

Type d'apprentissage	Tâche/Méthode	Machine Learning (ML) ✅	Deep Learning (DL) ✅	Besoin d'une valeur cible 📌
Apprentissage supervisé	Tâche de classification	✅ Oui	✅ Oui	✅ Oui (labels)
	Tâche de régression	✅ Oui	✅ Oui	✅ Oui (valeurs)
Apprentissage non supervisé	Clustering	✅ Oui	❌ Non	❌ Non
	Réduction de dimension (ACP, t-SNE)	✅ Oui	❌ Non	❌ Non
Apprentissage par renforcement	Apprentissage par renforcement	❌ Non	✅ Oui	👉 Oui

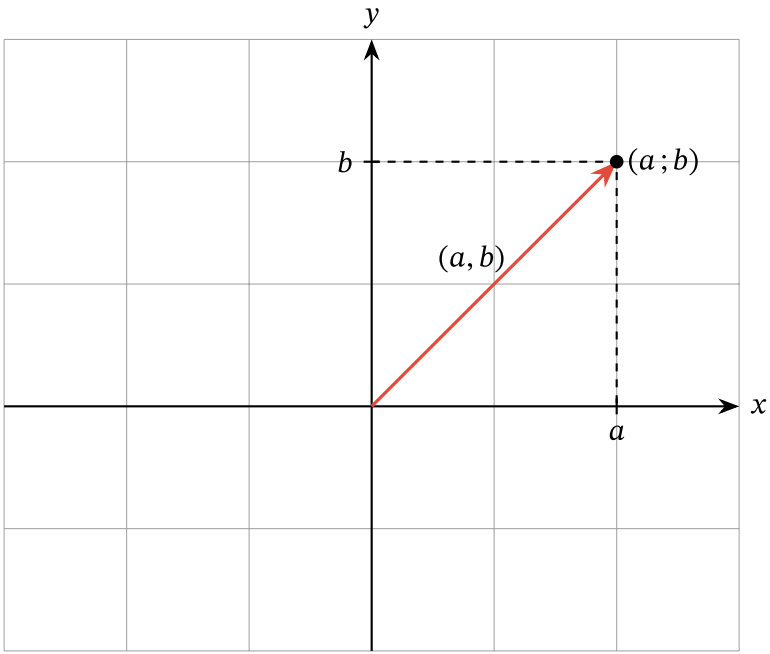
Une donnée, c'est quoi ?

Une **donnée** est une **information brute** qui peut être :

- 📊 **Numérique** : âge, prix, température...
- 💬 **Textuelle** : commentaires, tweets, articles...
- 📷 **Visuelle** : images, vidéos...
- 🎵 **Audio** : sons, musique, paroles...

Dans un **modèle mathématique ou informatique**, une donnée peut être **représentée sous forme de vecteur dans un espace à N-dimensions**.

Dans d'autres cas, une image peut être traité comme un ensemble de pixel



Définition

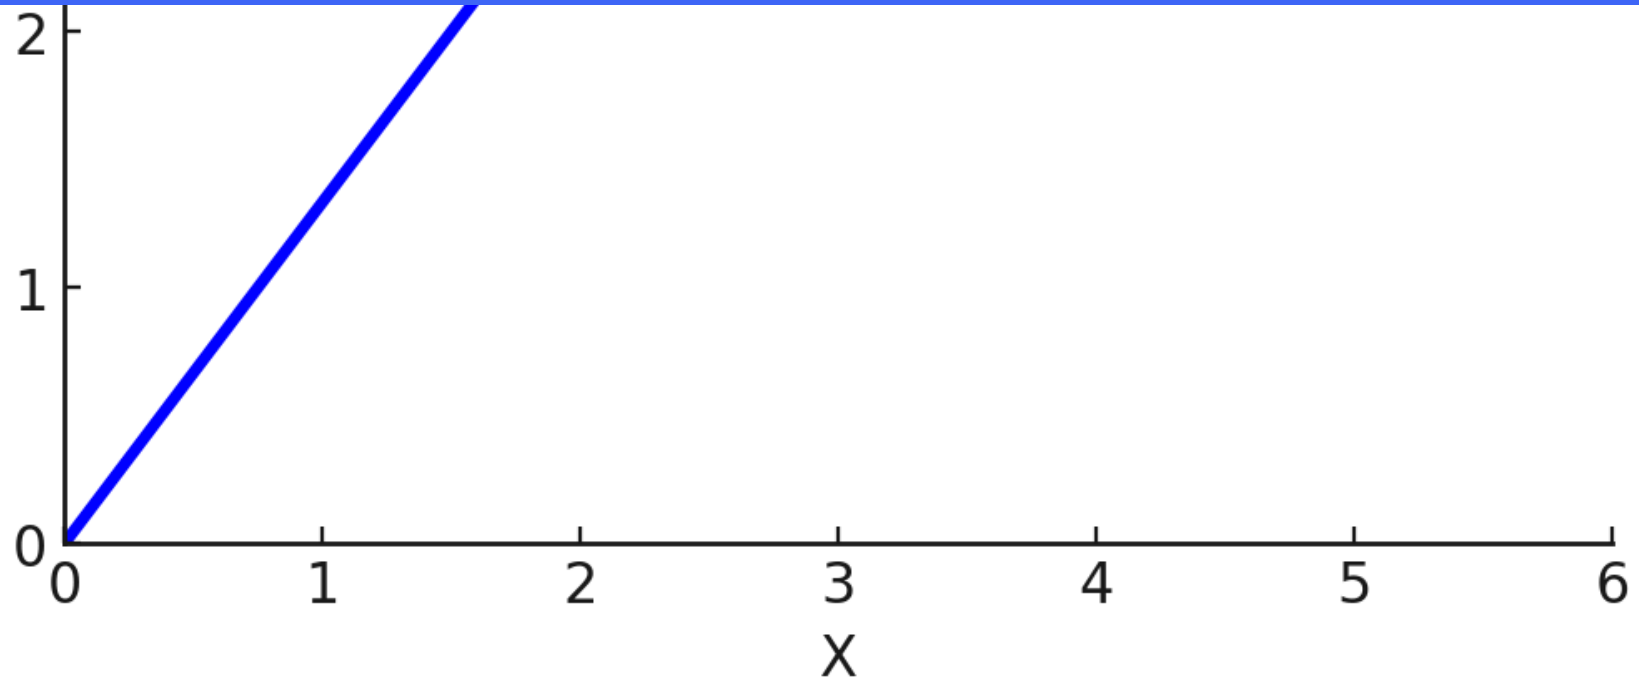
Un **vecteur** est une structure de données mathématique qui contient une **liste ordonnée de nombres**.

En data mining, un vecteur représente souvent les **caractéristiques** d'un objet ou d'une observation. Chaque dimension correspond à un attribut distinct.

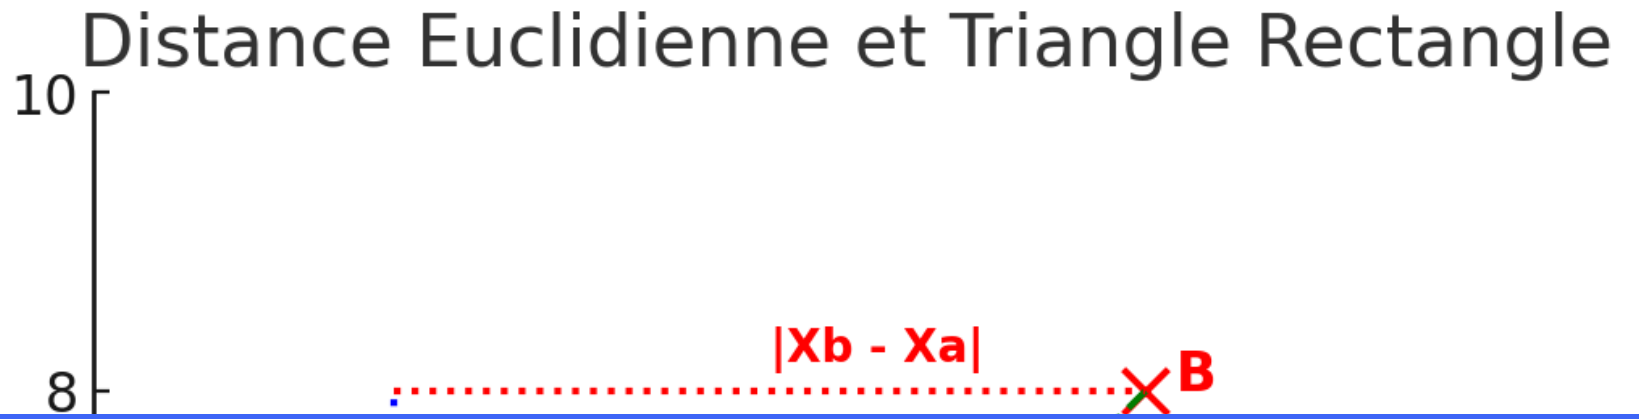
🎯 Comprendre la notion de vecteur

Informations utiles sur les vecteurs:

- Un vecteur $\vec{v}$ dans un espace à 2 dimensions peut être noté : $\vec{v} = (x, y)$
- Les vecteurs peuvent être manipulés mathématiquement (addition, multiplication par un scalaire)
- La **norme** (taille) d'un vecteur $\vec{v} = (x, y)$ est donnée par : $\|\vec{v}\| = \sqrt{x^2 + y^2}$
- La **distance euclidienne** entre deux vecteurs $\vec{v}_1 = (x_1, y_1)$ et $\vec{v}_2 = (x_2, y_2)$ est : $d(\vec{v}_1, \vec{v}_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$
- Pour des vecteurs à n dimensions $\vec{v}_1 = (x_1, x_2, \ldots, x_n)$ et $\vec{v}_2 = (y_1, y_2, \ldots, y_n)$, la distance euclidienne est : $d(\vec{v}_1, \vec{v}_2) = \sqrt{\sum_{i=1}^{n} (y_i - x_i)^2}$



La distance de manhattan



🎯 Comprendre la notion de vecteur

Analysons le tableau suivant:

📝 Données des étudiants

Étudiant	Âge	Moyenne en Math	Moyenne en physique	Sexe
Alice	18	15	10	F
Bob	25	12	12	M
Charlie	30	18	8	M
Diane	22	10	16	F

🎯 Comprendre la notion de vecteur

📊 Représentation vectorielle des étudiants

Dans un espace vectoriel **(âge, moyenne en math,physique, sexe)**, chaque étudiant est représenté sous forme de vecteur :

$$V_{Alice} = (18, 15, 10, F)$$

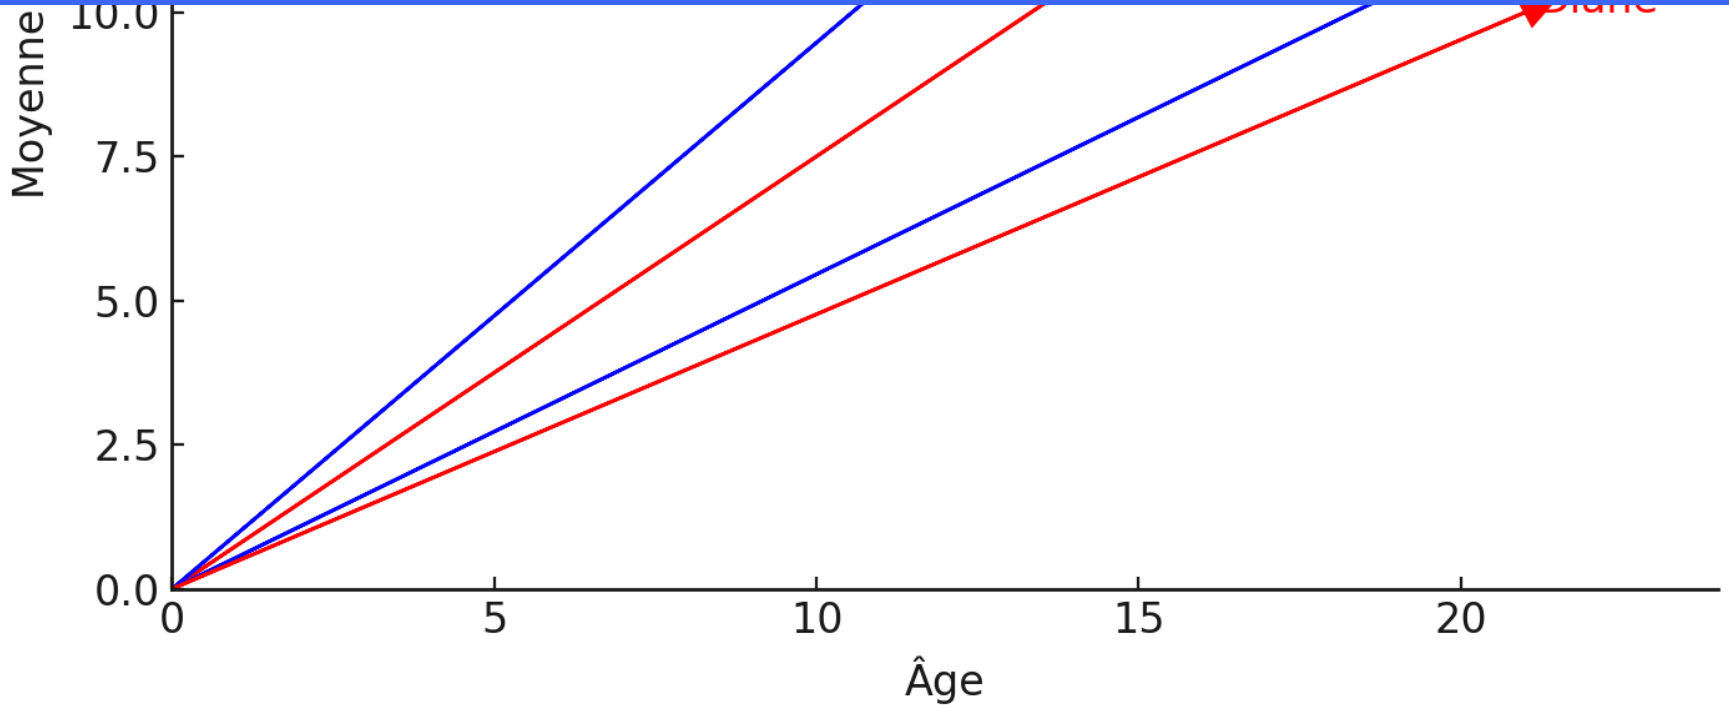
$$V_{Bob} = (25, 12, 12, M)$$

$$V_{Charlie} = (30, 18, 8, M)$$

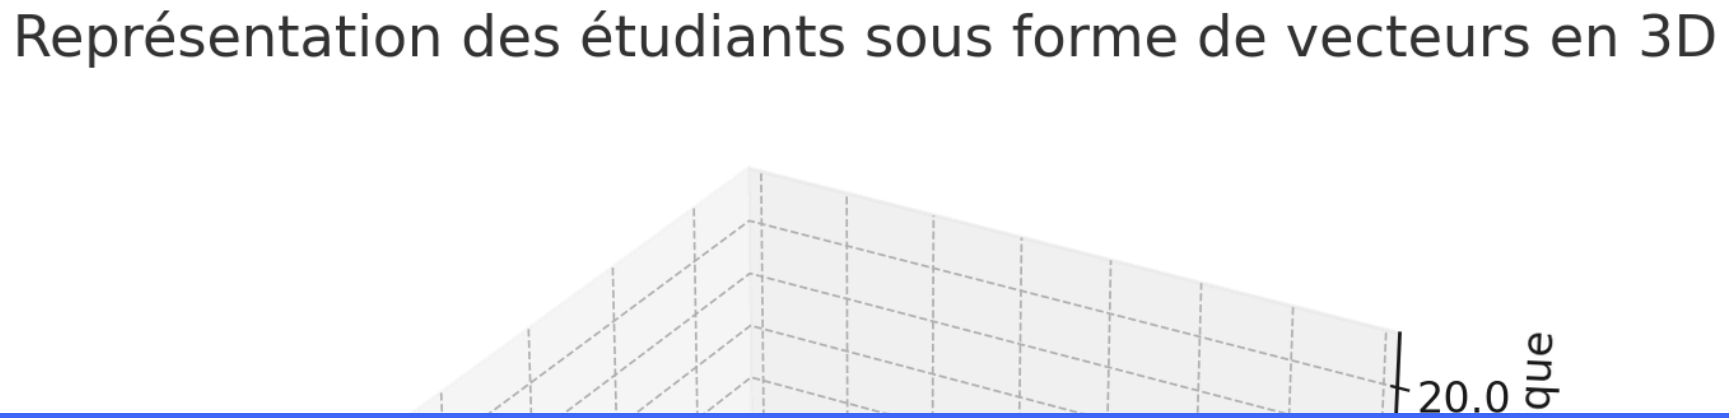
$$V_{Diane} = (22, 10, 16, F)$$

Remarque :

- Ici, le **sexe est encore une variable catégorielle**.
- Si on voulait **l'utiliser dans un modèle mathématique**, on devrait **le convertir en une valeur numérique** (ex : One-Hot Encoding ou Label Encoding).



Représentation dans un éspace en 3d



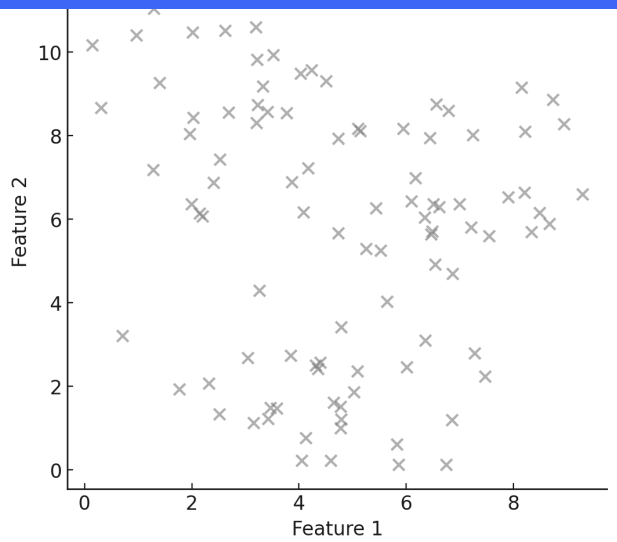
💡 Question ouverte

Pourquoi je vous parle de vecteur ?

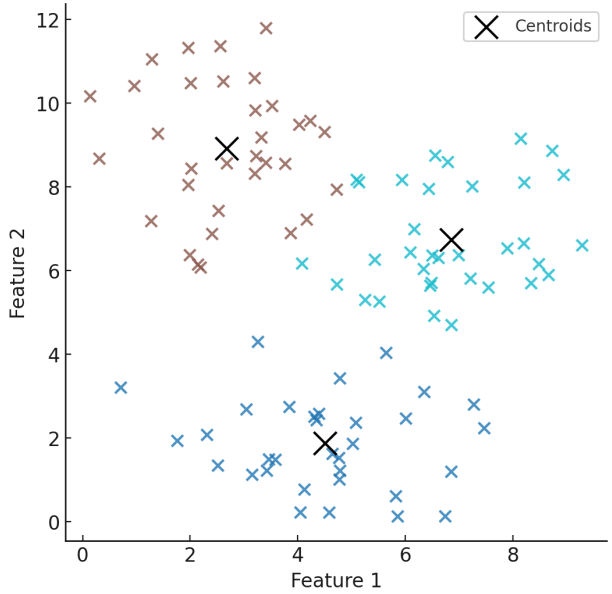
Partie 2: Analyse non supérvisé et clustering

Le **clustering** est une technique d'apprentissage non supervisé qui consiste à regrouper des points de données **sans label** en fonction de leurs **similarités**.

⭐ Clustering

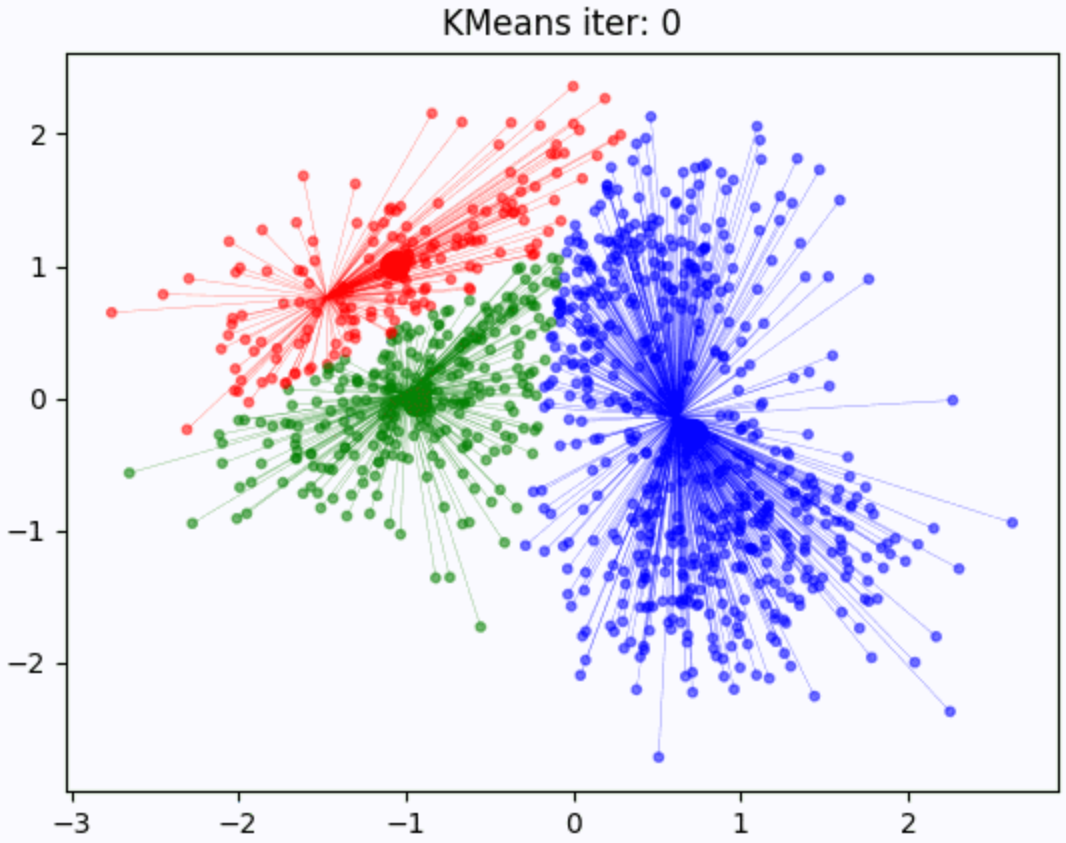


Points classifiés avec K-Means (K=3) - Couleurs vives

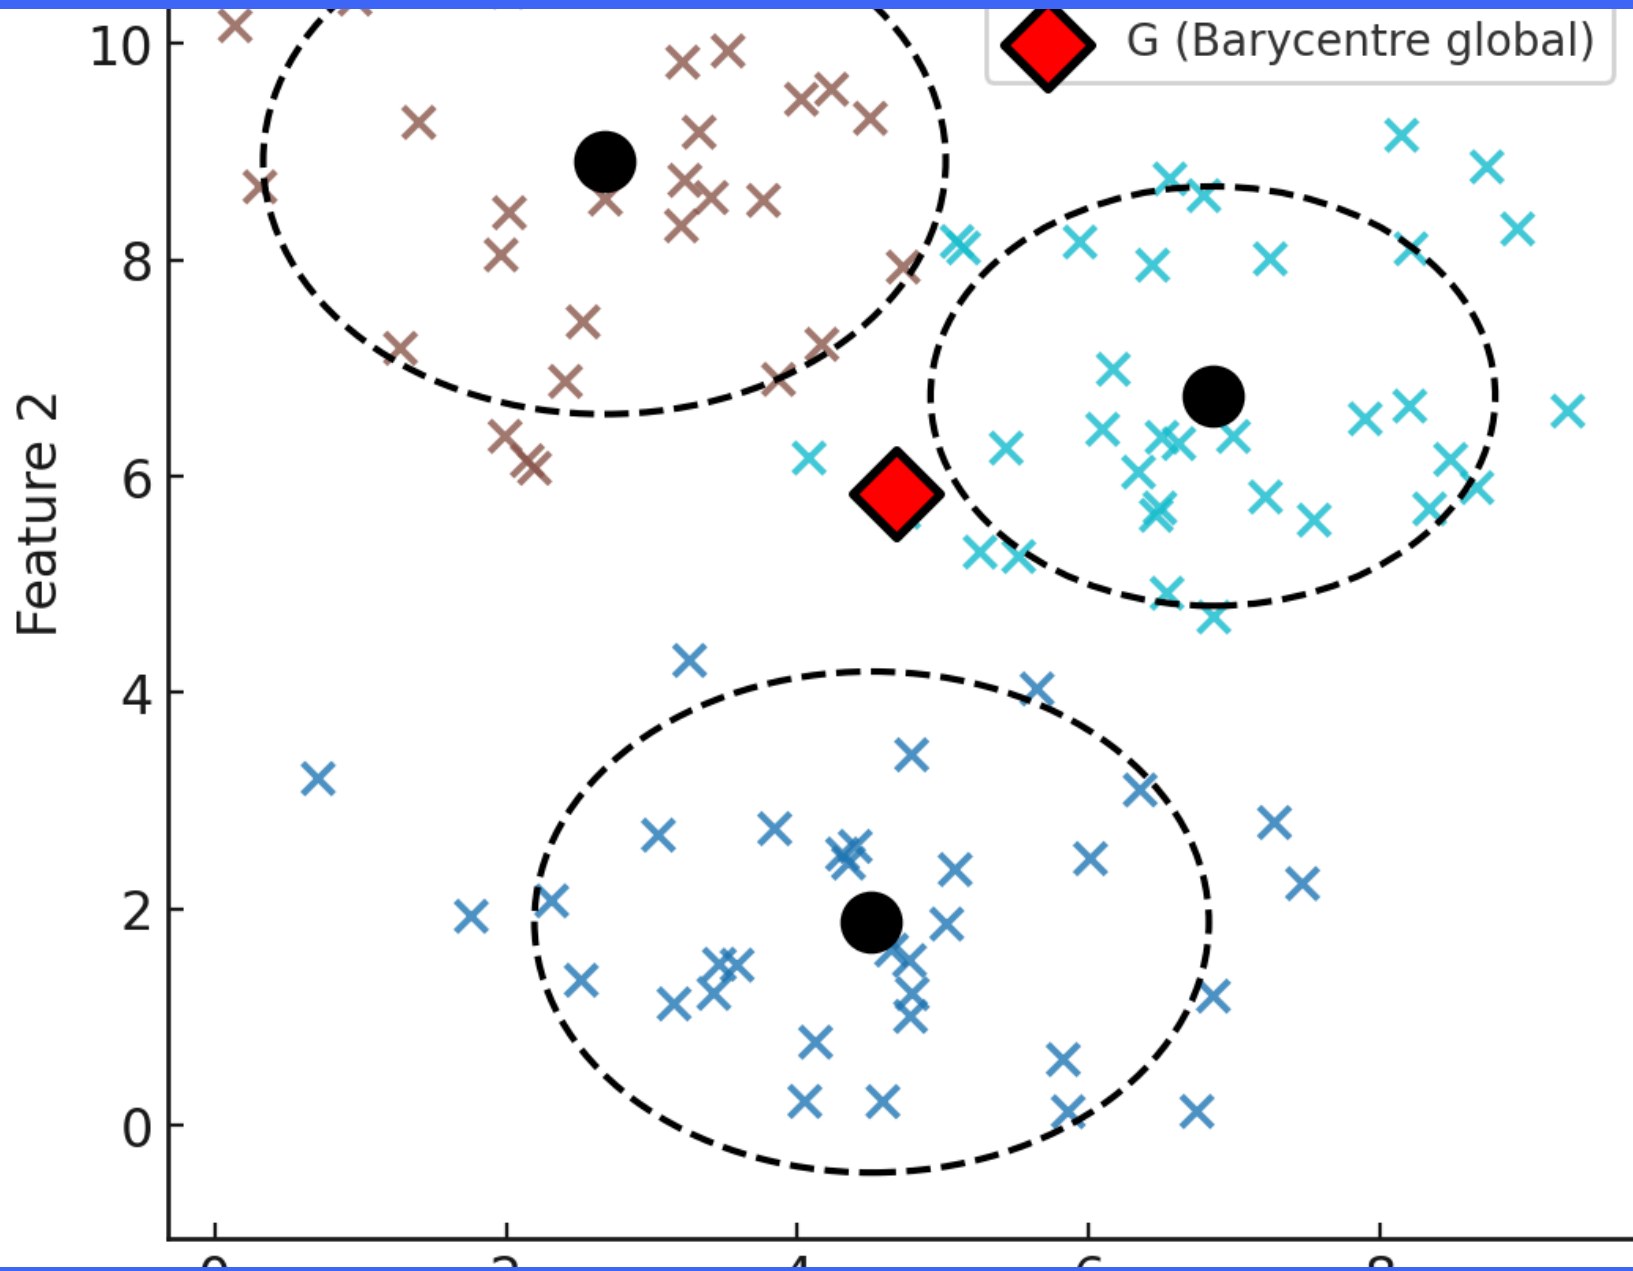


L'objectif du clustering est d'identifier dans un amas de points (**vecteurs**) les groupes qui

Entres les images précédentes voila les étapes du clustering :



Analysons ensemble


G (Barycentre global)
Feature 2
10
8
6
4
2
0

🎯 Comprendre le clustering encore + en détail

Nous allons voir le Théorème d'Huygens.

Il nous indique que:

$$Inertie_totale = Inertie_{inter-classe} + Inertie_{intra-classe}$$

Ou :

$$T = B + W$$

Ou:

$$\sum_{i=1}^{n} d^2(i, G) = \sum_{k=1}^{K} n_k d^2(G_k, G) + \sum_{k=1}^{K} \sum_{i=1}^{n_k} d^2(i, G_k)$$

Éxplication de la formule

$d^2(i, G)$: Distance quadratique entre un point i et le centre global G

G_k : Nombre total de clusters:

n_k: Nombre de points appartenant au cluster k:

$d^2(G_k, G)$: Distance quadratique entre le centroïde du cluster G_k et le centre global G:

$d^2(i, G_k)$: Distance quadratique entre un point i et le centroïde de son cluster G_k

Pour résoudre un problème de clustering il nous faut :

1. Fixer un nombre de classes K
2. Définir ou positionner les K classes de départ dans l'espace
3. Déplacer nos **centroïds** dans un espace décrivant nos données
4. Un objectif, une mission (pourquoi pas notre W)
5. Analyser nos partitions

Partie 3: Kmeans, les centres mobiles

🔍 Introduction au K-Means

Le K-Means est l'un des algorithmes de clustering les plus populaires.

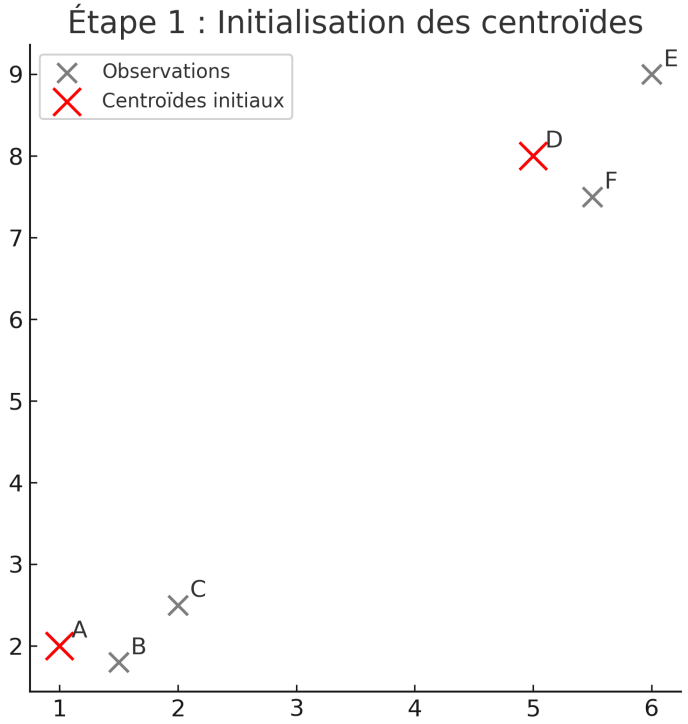
- Il divise les données en **K groupes**
- Chaque groupe a un **centroïde**, représentant son centre
- L'algorithme minimise la distance entre les points et leurs centroïdes
- Basé sur la minimisation des distances entre points et centroïdes
- Utilisé en segmentation, classification et réduction de données
- Fonctionne en itérations successives jusqu'à convergence

L'algorithme du kmeans

1. Positionnement de centroïds C_n dans l'éspace des données de façon aléatoire
2. Calcul de toutes distantes entre l'ensemble des centroïds C_n et les observation x_i:
   - $d(x_i, C_k) = \sqrt{(x_i - C_k)^2}$
3. Associer les donnes x_i aux centroids C_n le plus proches:
   - $x_i \in C_k \quad \text{si} \quad d(x_i, C_k) \leq d(x_i, C_j) \quad \forall j \neq k$
4. Mise à jour des centroids en respectant la formule suivante:
   - $\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$
5. Vérification du **critère d'arrêt** :
   - L'algorithme s'arrête si les centroïdes **ne bougent plus** :
     - $||C_k^{(t+1)} - C_k^{(t)}|| < \epsilon$
   - Ou si un **nombre maximal d'itérations** est atteint.
     - On prend souvent $\epsilon = 10^{-4}$ ou 10^{-5} pour s'assurer d'une bonne convergence.

Étape 1 : Initialisation des centroïdes

1. Choisir un nombre de clusters **K**
2. Sélectionner **K centroïdes aléatoires** parmi les observations
3. Définir ces centroïdes comme points initiaux

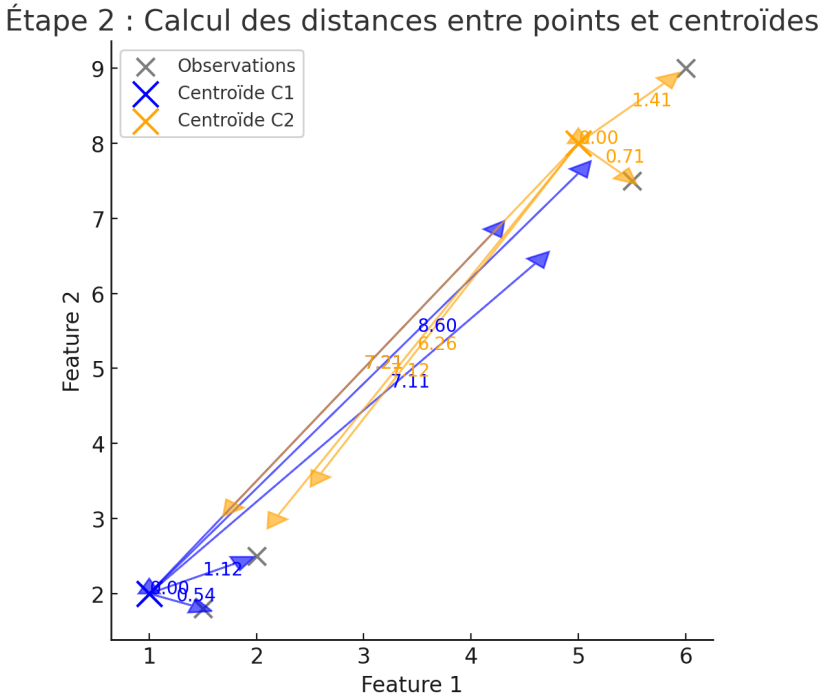


📊 Étape 2 : Calcul des distances

1. Calculer la **distance euclidienne** entre chaque point et chaque centroïde :

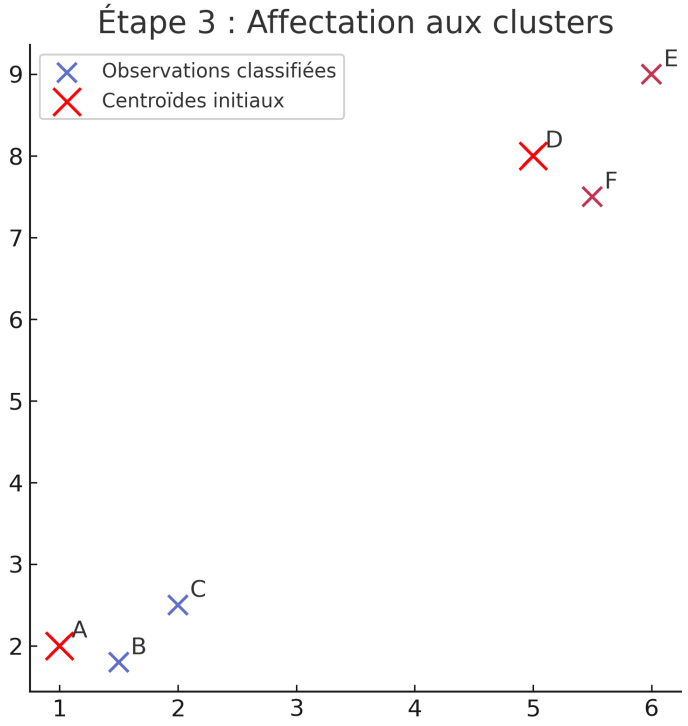
$$d(x_i, C_k) = \sqrt{(x_i - C_k)^2}$$

2. Assigner chaque point au centroïde **le plus proche**



💡 Étape 3 : Affectation aux clusters

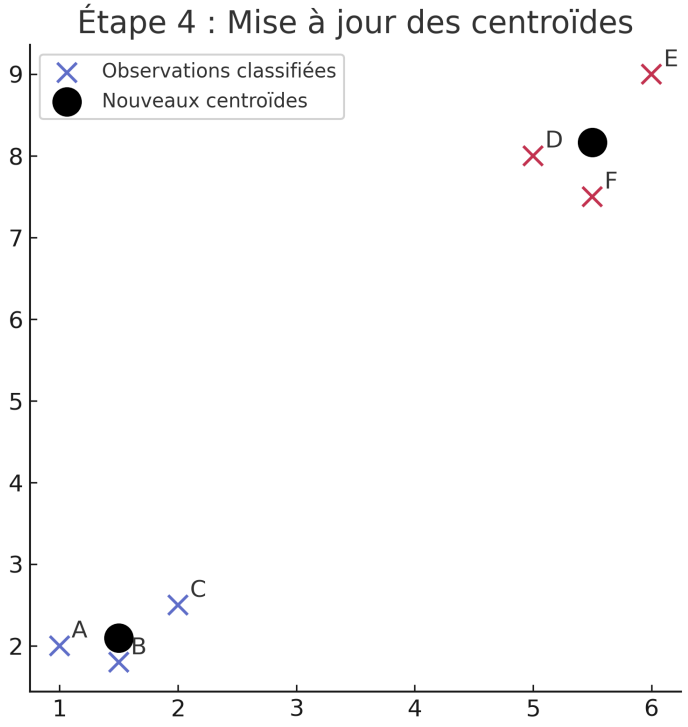
Chaque point est **attribué** au cluster dont il est **le plus proche**.
Cela crée une **première séparation** des données.



📈 Étape 4 : Mise à jour des centroïdes

1. Recalculer les **nouveaux centroïdes** en prenant la **moyenne** des points associés à chaque cluster :

$$C_k^{(new)} = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$



⚠ Étape 5 : Vérification du critère d'arrêt

L'algorithme s'arrête si :

- Les centroïdes **ne bougent plus** :
  $||C_k^{(t+1)} - C_k^{(t)}|| < \epsilon$
- Un **nombre maximum d'itérations** est atteint.

Points importants ⚠

- Le nombre de cluster est un point très important
- Comment mesurer les performance de mon **modèle** ?
- Le kmeans est très sensible aux **outliers** (traité dans la partie suivante)

Le nombre de cluster est un point très important

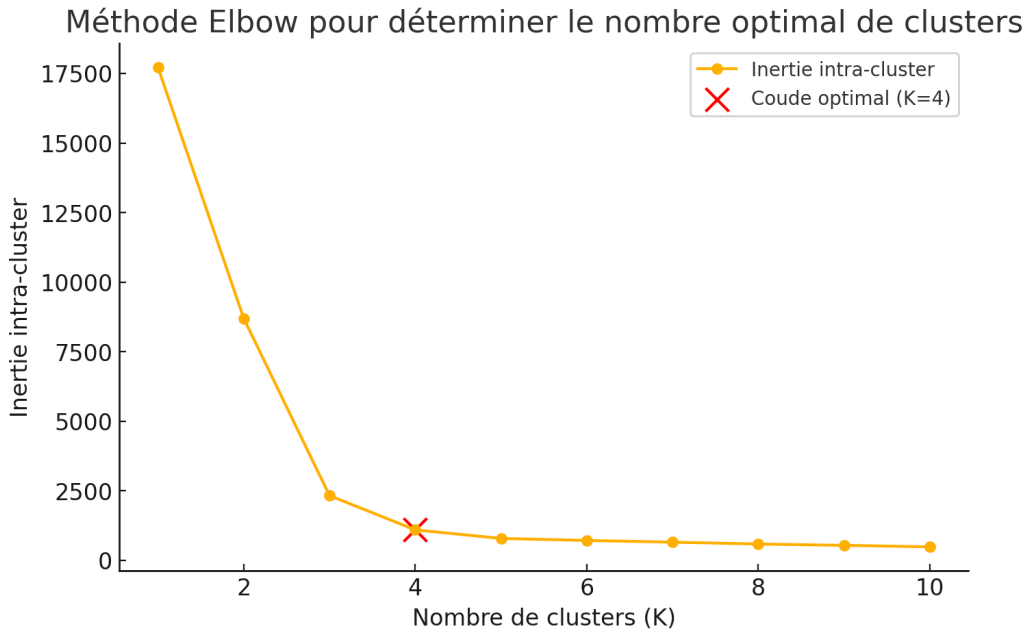
Une méthode nous permet de savoir comment établir notre nombre de clusters initiaux, la méthode **Elbow**.

Le but est simple exécuté plusieurs fois notre algorithme Kmeans avec des clusters allant de 1 à n pour voir l'évolution de W.
Nous pouvons nous arrêter au moment ou W ne bouge plus beaucoup. Impliquant qu'importe le nombre de futur cluster le minimum W n'aura plus de changement significatif.

La méthode elbow

📌 Explication :

- Le point en rouge (K=4) représente le "coude", où l'inertie cesse de diminuer de manière significative.



Comment mesurer les performance de mon modèle ?

1. Le score de silhouette
2. Le WSS

Silhouette : Mesure **la qualité du clustering** en évaluant **la cohésion** d'un cluster et **la séparation** avec les autres.

Formule :

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$ **: Cohésion**
  - Distance moyenne entre un point (i) et tous les autres points de son **propre cluster**.
- $b(i)$ **: Séparation**
  - Distance moyenne entre un point (i) et tous les points du **cluster voisin le plus proche**.

Interprétation du score :

- $S(i) \approx 1$ → Le point est bien dans son cluster.
- $S(i) \approx 0$ → Le point est proche d'un autre cluster.
- $S(i) < 0$ → Le point est probablement mal classé.

Le **SSE (Sum of Squared Errors)** mesure la **dispersion des points autour de leur centroïde**.

Formule :

$$SSE = \sum_{i=1}^{k} \sum_{x_j \in C_i} ||x_j - \mu_i||^2$$

Explication des termes :

- k : Nombre de clusters.
- x_j : Un point dans le cluster.
- C_i : Ensemble des points du cluster i.
- μ_i : Centroïde du cluster i.

Interprétation du score SSE :

SSE faible → Les points sont **proches de leurs centroïdes**
SSE élevé → Les points sont **éloignés de leurs centroïdes**
Problème → Le SSE **diminue toujours quand k augmente**, donc il **ne suffit pas** pour choisir le bon k (méthode Elbow recommandée !).

Ces deux métriques permettent d'évaluer et d'optimiser un modèle K-Means !

Partie 4: Comprendre comment éxploiter des données

- Pré-traitement des données
- Scaling de nos données

Le prétraitement des données est une étape **essentielle** en Machine Learning. Il permet d'améliorer la **qualité** et la **pertinence** des données avant leur utilisation dans un modèle.

Exemple de dataset brut :

Nom	Âge	Salaire	Ville	Score Test	Employé	Date Embauche
Alice	25	35000	Paris	78	Oui	2019-03-15
Bob	38	42000	Lyon	85	Non	2015-07-21
Charlie	NaN	30000	Marseille	65	Oui	2021-01-10
David	50	54000	Paris	90	Non	2010-09-12
Emma	29	NaN	Bordeaux	NaN	Oui	2018-06-30

Ce dataset brut contient plusieurs problèmes nécessitant un prétraitement.

🔍 1. Gestion des Données Manquantes

Détection des valeurs manquantes (`NaN`).
Techniques de traitement :

- Suppression si trop de valeurs manquantes.
- Imputation (moyenne, médiane, mode, prédiction).

Transformation du dataset après imputation :

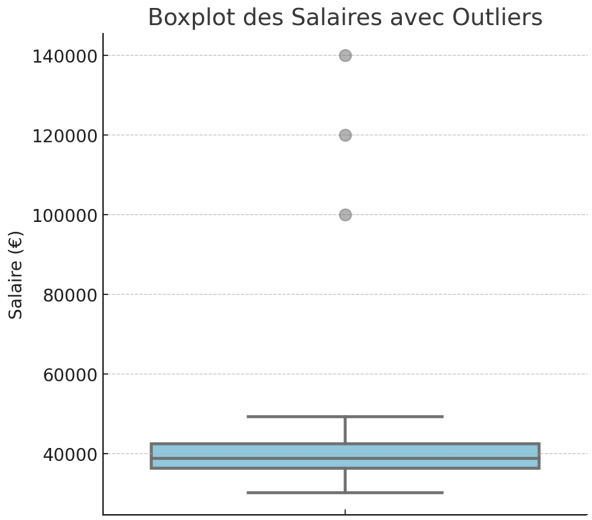
ID	Nom	Âge	Salaire	Ville	Score Test	Employé	Date Embauch
3	Charlie	34	30000	Marseille	65	Oui	2021-01-10
5	Emma	29	42000	Bordeaux	80	Oui	2018-06-30

🚪 2. Détection et Traitement des Outliers

Utilisation d'un boxplot pour détecter les outliers.
Techniques de gestion des valeurs aberrantes :

- Suppression des valeurs extrêmes.
- scaling.

Graphique des outliers (Boxplot sur les salaires) :



💻 3. Normalisation et Standardisation

Utilisation du MinMaxScaler, StandardScaler, RobustScaler.
Objectif : Mettre toutes les variables numériques sur la même échelle.
Transformation des valeurs :

ID	Nom	Âge Standardisé	Salaire Normalisé
1	Alice	-1.2	0.23
2	Bob	0.8	0.56

💻 3.bis Normalisation et Standardisation, comment choisir ?

StandardScaler (Standardisation) : Utilisé lorsque les données suivent une distribution **normale** (gaussienne). La formule mathématique est $X_{scaled} = \frac{X-\mu}{\sigma}$, où μ est la moyenne et σ l'écart-type.

MinMaxScaler (Normalisation) : Idéal lorsque les données doivent être **comprises entre 0 et 1**, particulièrement pour les réseaux neuronaux. La formule est $X_{scaled} = \frac{X-X_{min}}{X_{max}-X_{min}}$.

RobustScaler (Standardisation robuste) : Recommandé lorsque les données contiennent des **outliers** qui pourraient fausser la moyenne et l'écart-type. Utilise la formule $X_{scaled} = \frac{X-Q1}{Q3-Q1}$, où Q1 et Q3 sont les quartiles.

MaxAbsScaler (Normalisation) : Adapté lorsque les données ont des valeurs **positives et négatives** et doivent être **comprises entre -1 et 1**. La formule est $X_{scaled} = \frac{X}{|X_{max}|}$.

💻 3.bis bis Normalisation et Standardisation, pourquoi c'est important ?

Le scaling est crucial en Machine Learning et Deep Learning car :

- Évite la domination d'une feature sur une autre → Une variable avec de grandes valeurs (ex: salaire) peut écraser une autre (ex: âge).
- Accélère la convergence des modèles → Les algorithmes comme Gradient Descent convergent plus vite avec des valeurs bien mises à l'échelle.
- Améliore la précision → Certains modèles (K-Means, SVM, Réseaux de Neurones) sont sensibles à l'échelle des variables.
- Facilite l'interprétation des coefficients → Dans les modèles linéaires, standardiser permet d'avoir des coefficients comparables.

Sans scaling, un modèle peut mal apprendre ou être inefficace !

🚀 4. Encodage des Variables Catégorielles

One-Hot Encoding, Ordinal Encoding, Target Encoding.
Exemple de transformation :

ID	Paris	Lyon	Marseille	Bordeaux
1	1	0	0	0
2	0	1	0	0

🔧 5. Binarisation des Variables

Transformation des variables booléennes en 0 et 1.
Exemple :

ID	Employé (binaire)
1	1
2	0

🏆 6. Sélection et Création de Caractéristiques

Feature Engineering : Création de nouvelles variables pertinentes.
Exemple : Transformation des dates.

ID	Ancienneté (années)
1	5
2	9

Ce processus de prétraitement améliore la qualité des données avant leur utilisation dans un modèle de Machine Learning.

Des questions ?