Le Data Mining

Christopher de Boisvillierrs

2025-03-17

Partie 1: Introduction

📊 Qu'est-ce que le Data Mining ?

📌 Définition : Le **Data Mining**, ou **exploration de données**, est une technique qui permet d'**analyser de grandes quantités de données** afin d'y découvrir des **tendances, des modèles cachés et des relations utiles**.

À quoi ça sert ?

- 🔍 **Trouver des liens** entre différentes données

  Exemple : quels produits sont souvent achetés ensemble ?

- 🚨 **Détecter des anomalies**

  Exemple : repérer une fraude bancaire en analysant des transactions inhabituelles.

- 🗂️ **Classer des données** en catégories

  Exemple : un email est-il un spam ou non ?

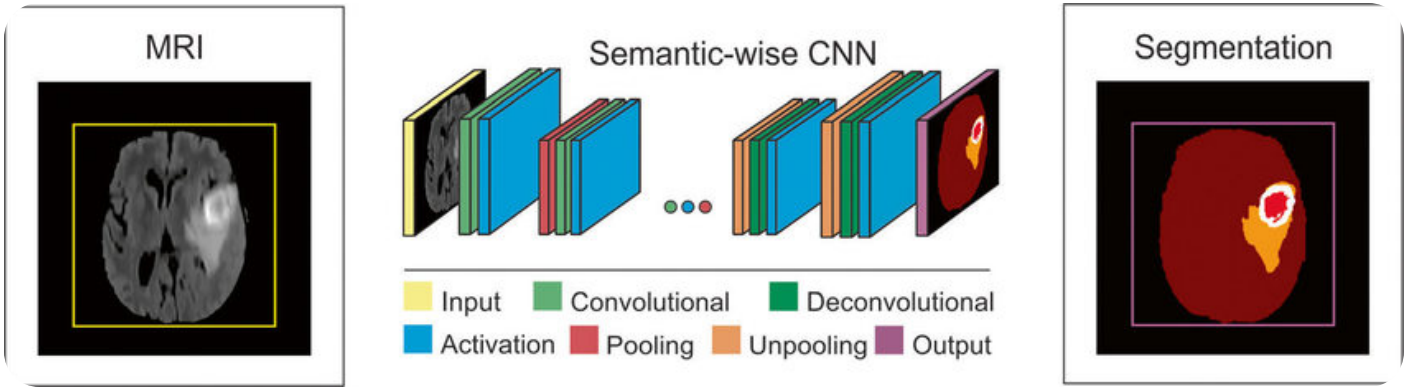
- 📈 **Prédire des valeurs (régression)**

  Exemple : estimer le prix d'une maison en fonction de sa surface.

Des exemples concrets (1/3) ? 🔍 *La tumeur*

- 🏥 **Médecine**

  Détection d'une tumeur chez un patient



Le but du jeu sera de trouver un **LIEN** permettant de différencier des cerveaux sain et d'autres atteints d'une tumeur.

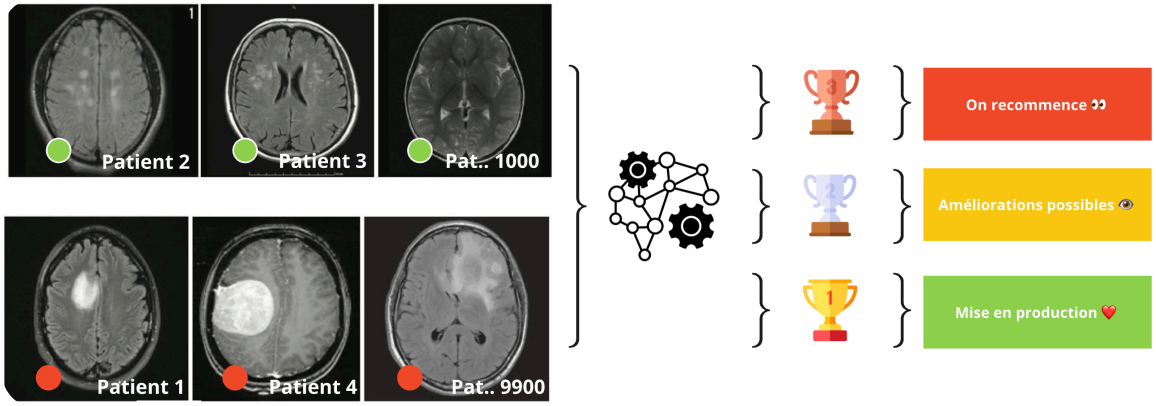
Nous pouvons déja imaginer un **DATASET** qui se presentera de la sorte:

Patient	image	Tumeur détectée (*Classe*)
Patient 1	patient_1.png	Oui
Patient 2	patient_2.png	Non

Des exemples concrets (1/3) ? 🔍 *La tumeur*

La recette pour trouver ce fameux **LIEN** ?

1. **Collecte des données** : collecter des IRM de patients avec et sans tumeurs.
2. **Prétraitement** : nettoyer, *normaliser*, redimensionner les données.
3. **Modélisation** : entraîner un algorithme de *classification* (ex: CNN, Random Forest).
4. **Évaluation** : **mesurer** la **précision**, le **rappel**, la **matrice de confusion**.



Approfondir le sujet : Brain Tumor Classification with CNN using TensorFlow

💡 Question ouverte

Quels autres critères pourraient aider à savoir si le patient à une tumeur ?

Des exemples concrets (2/3) ? 🔍 *Estimation du prix d'un bien immobilier ?*

Imaginons que nous voulons **prédire le prix** d'une maison en fonction de plusieurs critères:

- 🏠 **Surface de la maison (m²)**
- 🚩 **Localisation** (quartier, proximité des écoles, commerces…)
- 🚗 **Nombre de places de parking**
- 🍽️ **Présence d'une piscine**

Problème : Comment trouver un lien entre des données que l'agence possède et le prix d'une maison/appt.

Des exemples concrets (2/3) ? 🔍 ***Estimation du prix d'un bien immobilier ?***

Voici le dataset que possède l'agence comme source de données.

Maison ID	Surface (m²)	Quartier	Parking	Piscine	Prix (*Cible*)
1	120	Centre	1	Oui	350 000
2	80	Banlieue	0	Non	180 000
3	150	Centre	2	Oui	500 000
4	90	Périphérie	1	Non	220 000

Nous souhaitons trouver un lien entre notre dataset et la variable **cible** prix

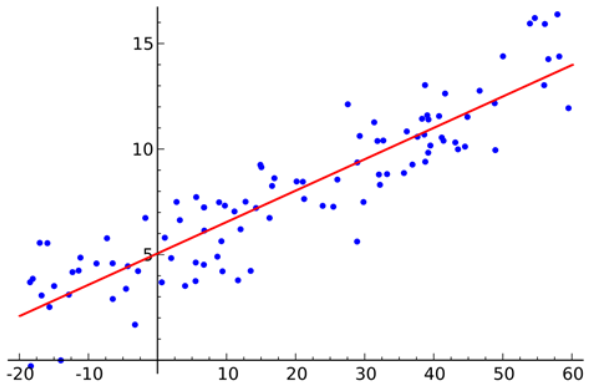
Des exemples concrets (2/3) ? 🔍 ***Estimation du prix d'un bien immobilier ?***

La recette pour trouver ce fameux **LIEN** ?

1. **Collecte des données** : Historique des ventes immobilières.
2. **Prétraitement** : Nettoyage des données, transformation des variables catégorielles.
3. **Modélisation** : **Modèle** pour trouver les **facteurs influençant le prix**.
4. **Prédiction** : Estimer le prix d'une nouvelle maison selon ses caractéristiques.
5. **Évaluation** : Vérification avec les indicateurs **MAE, RMSE, R^2**.

Des exemples concrets (2/3) ? 🔍 *Estimation du prix d'un bien immobilier ?*

- **Relation entre surface et prix :**



Impact des caractéristiques :

- Une **maison plus grande** coûte généralement **plus cher**.
- Un **quartier central** augmente la valeur.
- La **présence d'une piscine** ajoute une **valeur significative**.

Conclusion : Grâce au modèle, l'agent immobilier peut **prédire un prix réaliste** pour chaque maison et mieux conseiller ses clients.

💡 Question ouverte

Quels autres critères pourraient influencer le prix d'une maison ?

Des exemples concrets (3/3) ? 🔍 *Classification de patients à risque*

📌 Contexte

Un hôpital souhaite **analyser ses patients** pour mieux comprendre **les facteurs de risque** associés à certaines maladies comme le diabète ou les maladies cardiaques. Cependant, les médecins ne connaissent **pas à l'avance** les catégories de patients à risque.

C'est un problème de **clustering** où nous cherchons à découvrir des groupes naturels dans les données sans avoir d'étiquettes prédéfinies.

💡 **Objectif** : Utiliser un algorithme pour **regrouper automatiquement** les patients en fonction de leurs caractéristiques médicales.

🔍 Collecte de nos données

Nous disposons d'un **dataset médical** contenant plusieurs variables :

Patient	Âge	IMC	Tension	Glycémie	Activité (h/semaine)
Patient 1	65	30	140/90	1.5	0
Patient 2	45	25	120/80	0.9	5
Patient 3	55	32	135/85	1.8	1
Patient 4	38	22	115/75	0.7	7
Patient 5	60	35	145/95	2.0	0.5

📌 **Problème** : Comment sans différentes classe au préalable je peux différencier mes patients ?

🔍 Application d'un algorithme de clustering

🔧 Étapes du clustering :

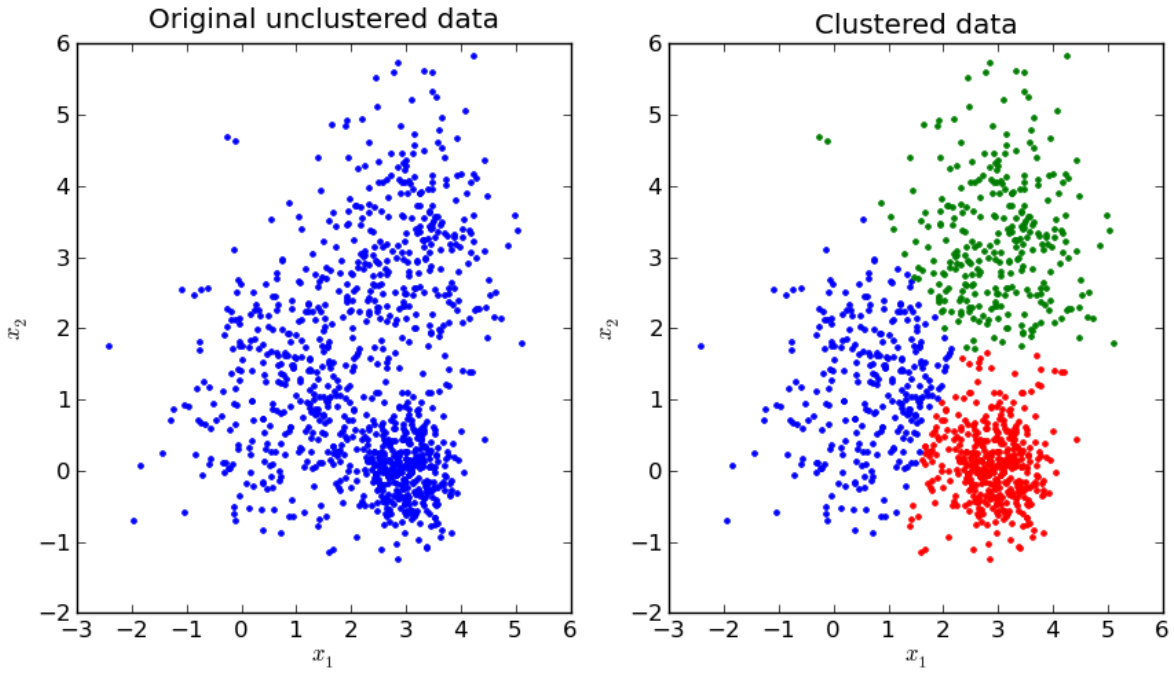
1. **Prétraitement des données** : **Normalisation** des valeurs (âge, IMC, glycémie...).
2. **Estimer un nombre de cluster** : Test avec **K=3**.
3. **Clustering** : Regroupe les patients en fonction de leur **profil médical**.
4. **Analyse des groupes** : Identifier les **facteurs communs** dans chaque groupe.

💡 Résultats et interprétation

Après application **d'un algorithme de clustering**, on obtient **trois groupes distincts** :

Cluster	Profil des patients	Risque médical
Groupe 1	Patients jeunes, activité physique élevée, glycémie normale	**Faible**
Groupe 2	Patients d'âge moyen, IMC modéré, glycémie légèrement élevée	**Moyen**
Groupe 3	Patients âgés, obèses, glycémie élevée, faible activité physique	**Élevé**

Visualisation des clusters :



Conclusion : L'hôpital peut utiliser ces groupes pour **cibler les patients à risque élevé** et leur proposer des **programmes de prévention** adaptés.

💡 Question ouverte

Dans quels autres domaines pourrait-on utiliser du clustering pour regrouper des individus ou objets ?

💡 Question

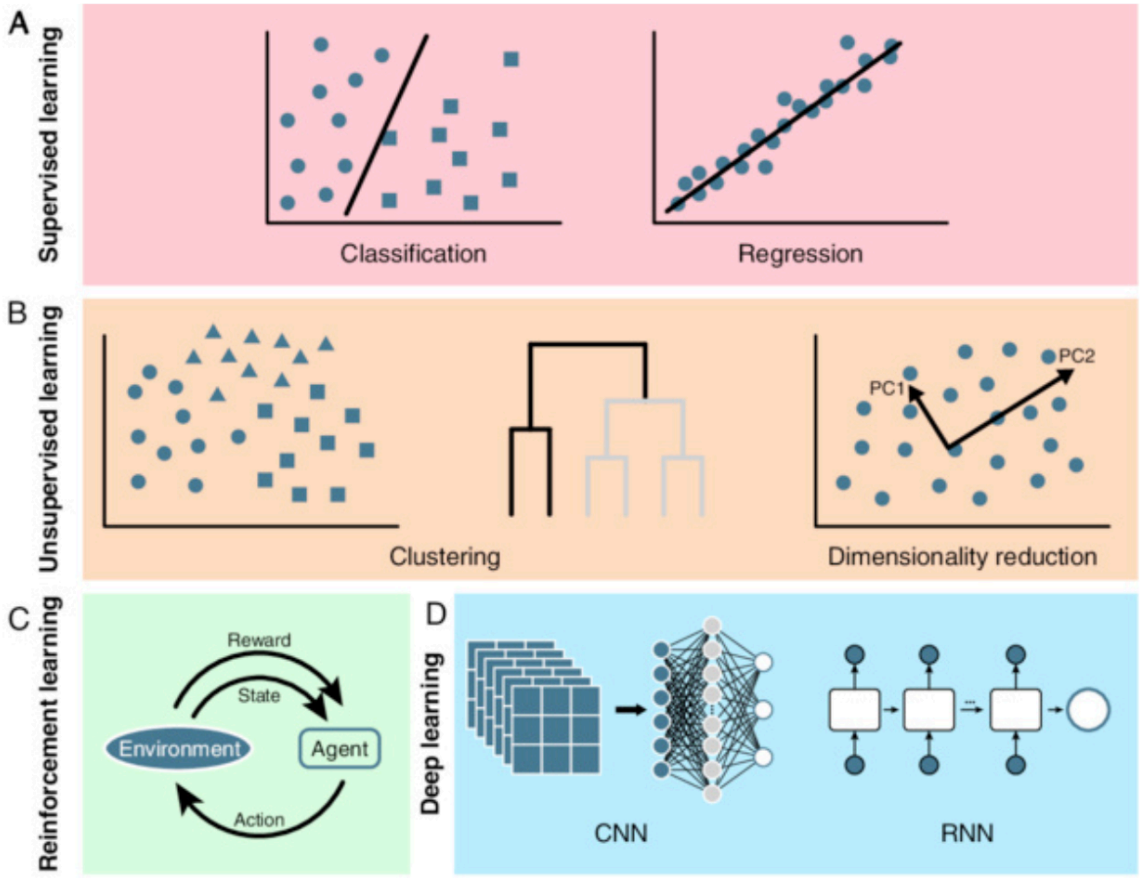
Qu'avez-vous remarqué dans les trois exemples précédents ?

Réponse:

Cas d'étude	Cible	KPI	Type
1	Classe (tumeur ou non)	Rappel,matrice de confusion etc	Supérvisé
2	Prix (valeur numérique)	R^2, mae	Supérvisé
3	Aucune	silhouette	Non Supérvisé

Il éxiste donc des familles d'algorithmes ?

Regardons l'image suivante :



Il éxiste donc des familles d'algorithmes ?

Type d'apprentissage	Tâche/Méthode	Machine Learning (ML) ✅	Deep Learning (DL) ✅	Besoin d'une valeur cible 📌
Apprentissage supervisé	Tâche de classification	✅ Oui	✅ Oui	✅ Oui (labels)
	Tâche de régression	✅ Oui	✅ Oui	✅ Oui (valeurs)
Apprentissage non supervisé	Clustering	✅ Oui	❌ Non	❌ Non
	Réduction de dimension (ACP, t-SNE)	✅ Oui	❌ Non	❌ Non
Apprentissage par renforcement	Apprentissage par renforcement	❌ Non	✅ Oui	👉 Oui

Une donnée, c'est quoi ?

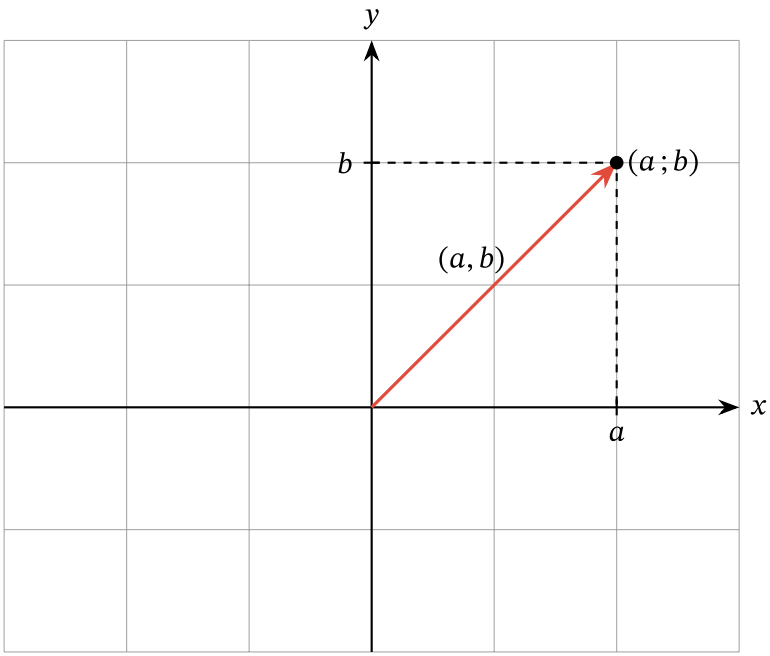
Une **donnée** est une **information brute** qui peut être :

- 📊 **Numérique** : âge, prix, température...
- 💬 **Textuelle** : commentaires, tweets, articles...
- 📷 **Visuelle** : images, vidéos...
- 🎵 **Audio** : sons, musique, paroles...

Dans un **modèle mathématique ou informatique**, une donnée peut être **représentée sous forme de vecteur dans un espace à N-dimensions**.

Dans d'autres cas, une image peut être traité comme un ensemble de pixel

🎯 Comprendre la notion de vecteur



Définition

Un **vecteur** est une structure de données mathématique qui contient une **liste ordonnée de nombres**.

En data mining, un vecteur représente souvent les **caractéristiques** d'un objet ou d'une observation. Chaque dimension correspond à un attribut distinct.

Exemple: Un patient peut être représenté par le vecteur [âge, poids, taille, tension].

🎯 Comprendre la notion de vecteur

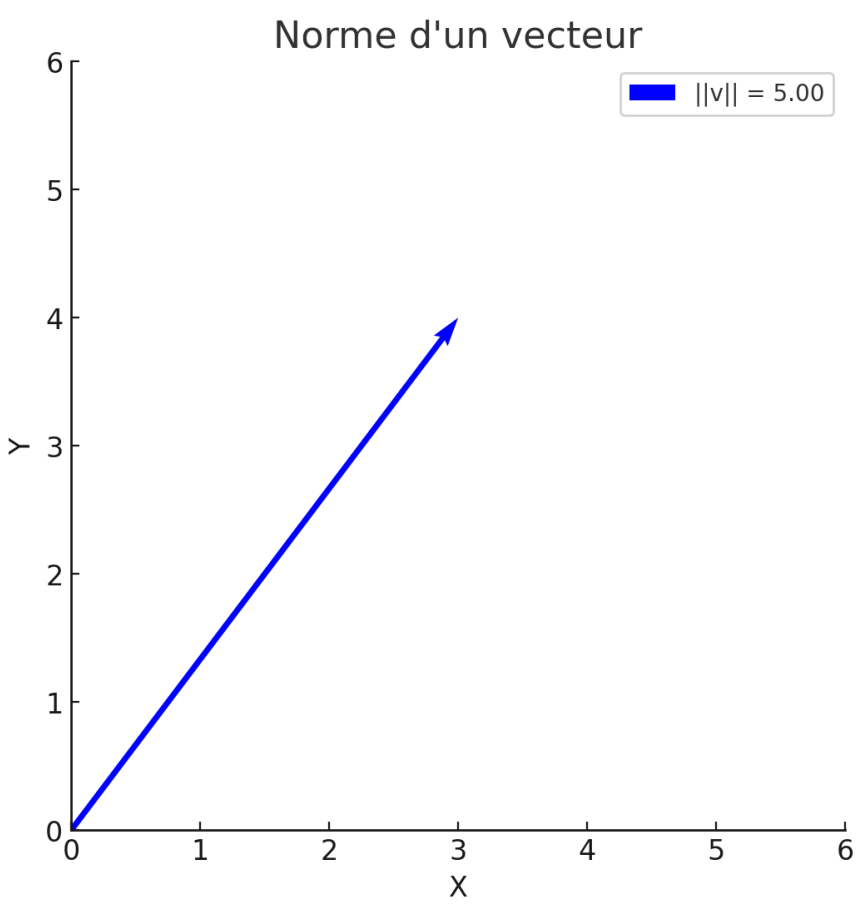
Informations utiles sur les vecteurs:

- Un vecteur $\vec{v}$ dans un espace à 2 dimensions peut être noté : $\vec{v} = (x, y)$
- Les vecteurs peuvent être manipulés mathématiquement (addition, multiplication par un scalaire)
- La **norme** (taille) d'un vecteur $\vec{v} = (x, y)$ est donnée par : $\|\vec{v}\| = \sqrt{x^2 + y^2}$
- La **distance de Manhattan** entre deux vecteurs $\vec{v}_1 = (x_1, y_1)$ et $\vec{v}_2 = (x_2, y_2)$ est : $d(\vec{v}_1, \vec{v}_2) = |x_2 - x_1| + |y_2 - y_1|$
- Pour des vecteurs à n dimensions $\vec{v}_1 = (x_1, x_2, \ldots, x_n)$ et $\vec{v}_2 = (y_1, y_2, \ldots, y_n)$, la distance de Manhattan est : $d(\vec{v}_1, \vec{v}_2) = \sum_{i=1}^{n} |y_i - x_i|$

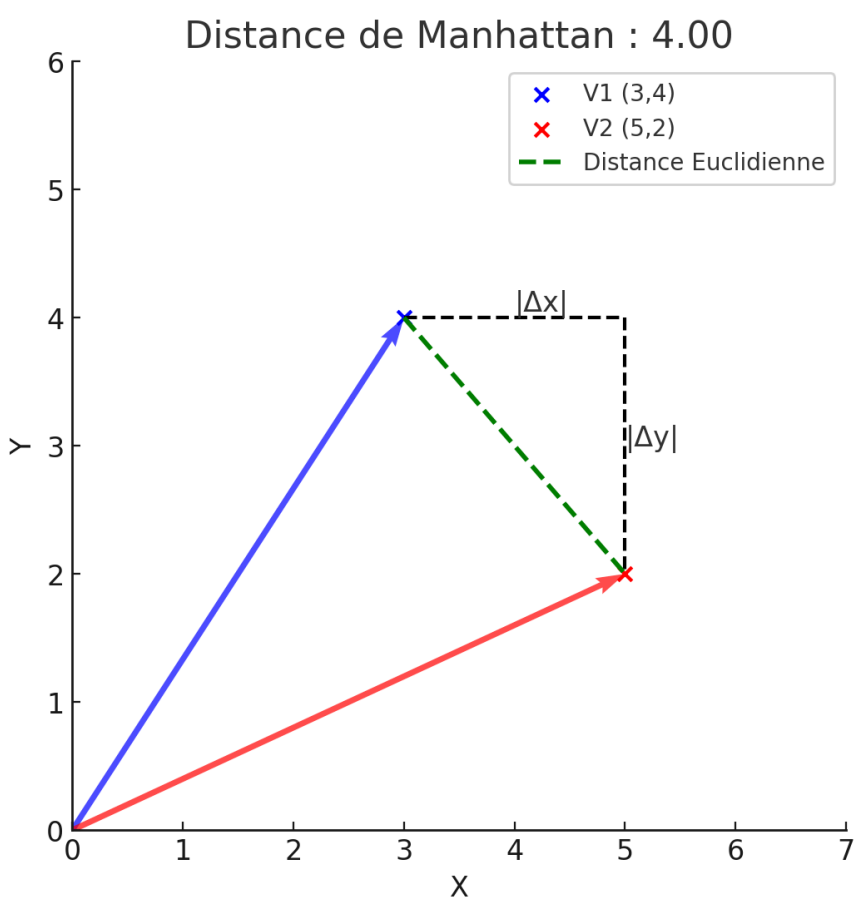
🎯 Comprendre la notion de vecteur

Plus visuellement

La norme



La distance de manhattan



🎯 Comprendre la notion de vecteur

Analysons le tableau suivant:

📝 Données des étudiants

Étudiant	Âge	Moyenne en Math	Moyenne en physique	Sexe
Alice	18	15	10	F
Bob	25	12	12	M
Charlie	30	18	8	M
Diane	22	10	16	F

🎯 Comprendre la notion de vecteur

📊 Représentation vectorielle des étudiants

Dans un espace vectoriel **(âge, moyenne en math,physique, sexe)**, chaque étudiant est représenté sous forme de vecteur :

$$V_{Alice} = (18, 15, 10, F)$$

$$V_{Bob} = (25, 12, 12, M)$$

$$V_{Charlie} = (30, 18, 8, M)$$

$$V_{Diane} = (22, 10, 16, F)$$

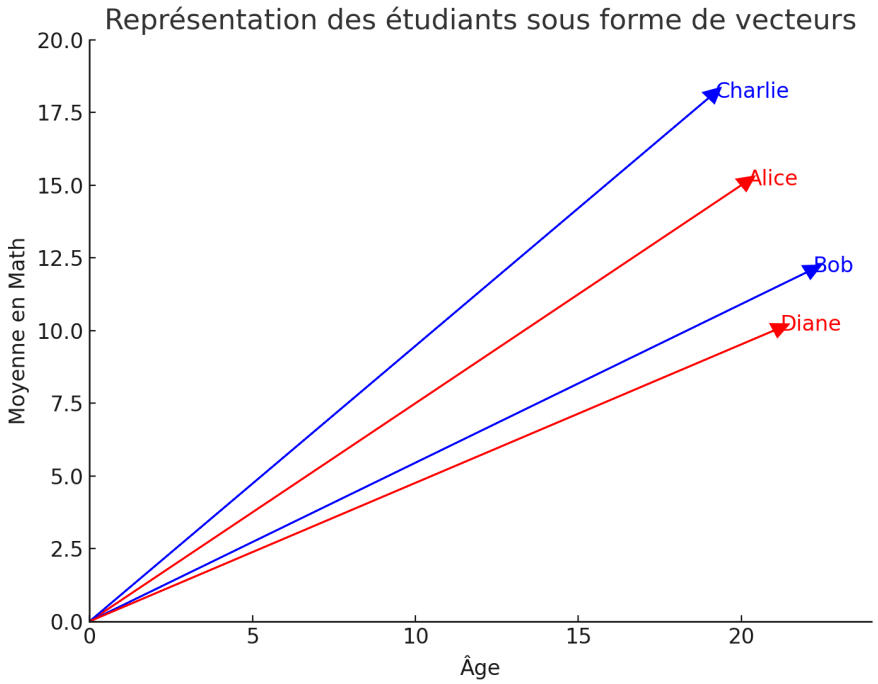
Remarque :

- Ici, le **sexe est encore une variable catégorielle**.
- Si on voulait **l'utiliser dans un modèle mathématique**, on devrait **le convertir en une valeur numérique** (ex : One-Hot Encoding ou Label Encoding).

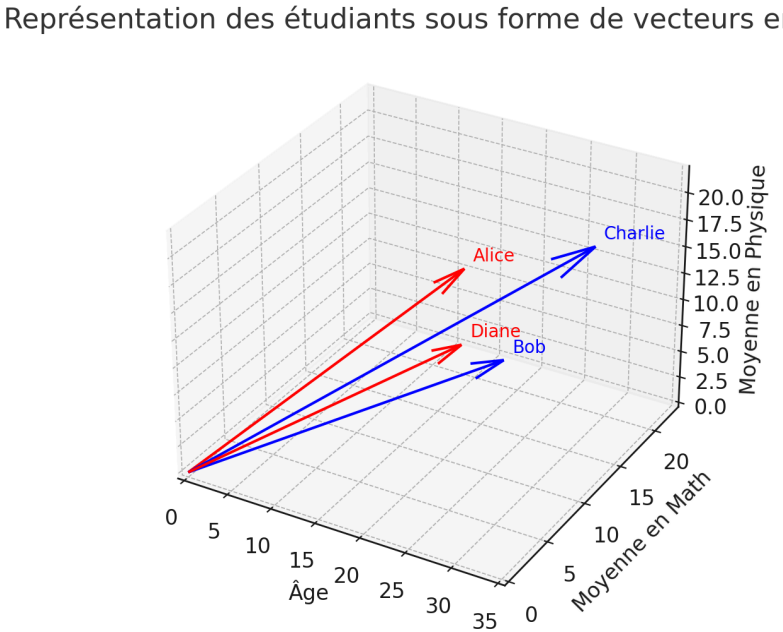
🎯 Comprendre la notion de vecteur

Plus visuellement

Représentation dans un éspace à 2d



Représentation dans un éspace à 3d



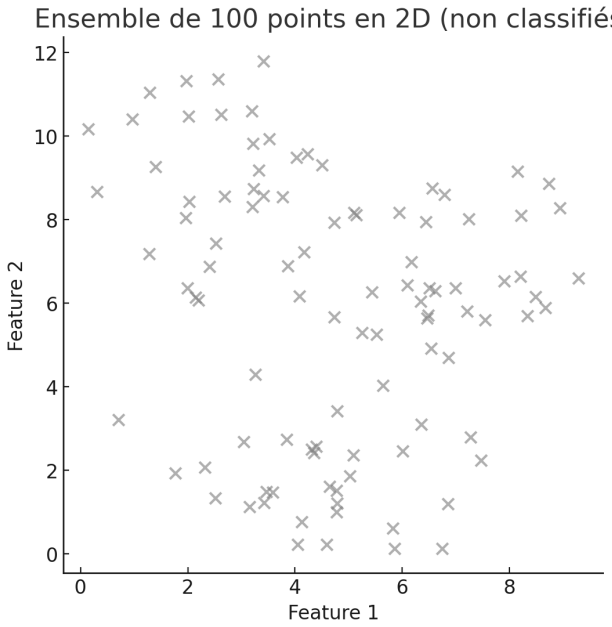
💡 Question ouverte

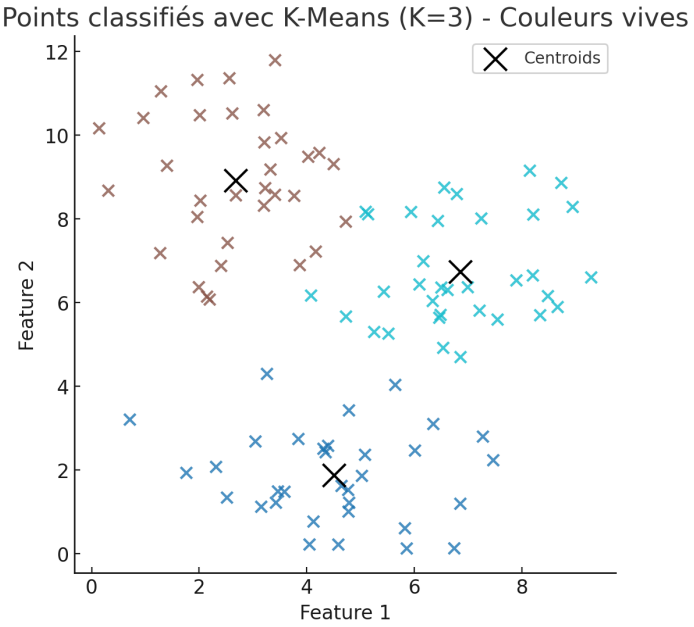
Pourquoi je vous parle de vecteur ?

Partie 2: Analyse non supérvisé et clustering

Le **clustering** est une technique d'apprentissage non supervisé qui consiste à regrouper des points de données **sans label** en fonction de leurs **similarités**.

🎯 Comprendre le clustering

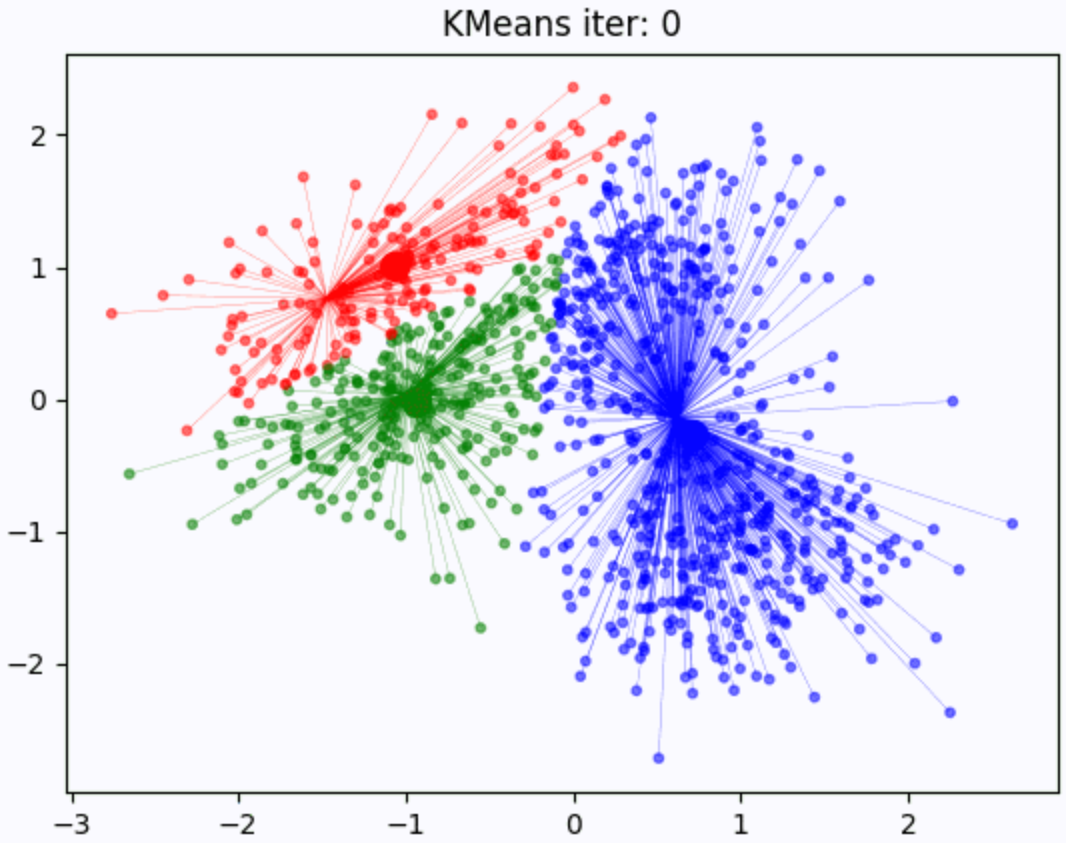




L'objectif du clustering est d'identifier dans un amas de points (**vecteurs**) les groupes qui pourraient se former naturellement.

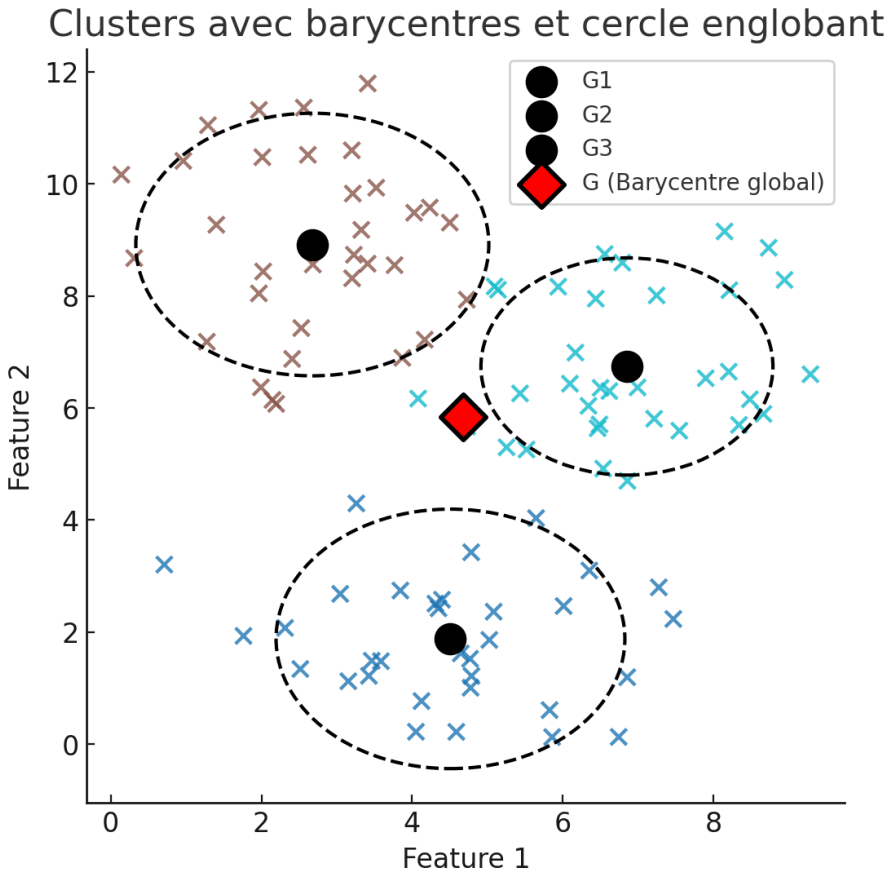
Pour réussir à répondre à cette problématique il nous faut quoi ?

Entres les images précédentes voila les étapes du clustering :



Analysons ensemble

🎯 Comprendre le clustering en détail



Donner un rôle crucial aux centres des classes

Les centroïds bougent dans l'espace afin de trouver leurs positionnements idéals

Il nous faut minimiser la dispersion des données dans chacuns des groupes (inertie intra classe)

🎯 Comprendre le clustering encore + en détail

Nous allons voir le Théorème d'Huygens.

Il nous indique que:

$$Inertie_totale = Inertie_{inter-classe} + Inertie_{intra-classe}$$

Ou :

$$T = B + W$$

Ou:

$$\sum_{i=1}^{n} d^2(i, G) = \sum_{k=1}^{K} n_k d^2(G_k, G) + \sum_{k=1}^{K} \sum_{i=1}^{n_k} d^2(i, G_k)$$

Éxplication de la formule

$d^2(i, G)$: Distance quadratique entre un point i et le centre global G

G_k : Nombre total de clusters:

n_k: Nombre de points appartenant au cluster k:

$d^2(G_k, G)$: Distance quadratique entre le centroïde du cluster G_k et le centre global G:

$d^2(i, G_k)$: Distance quadratique entre un point i et le centroïde de son cluster G_k

Pour résoudre un problème de clustering il nous faut :

1. Fixer un nombre de classes K
2. Définir ou positionner les K classes de départ dans l'espace
3. Déplacer nos **centroïds** dans un espace décrivant nos données
4. Un objectif, une mission (pourquoi pas notre W)
5. Analyser nos partitions

Partie 3: Kmeans, les centres mobiles

🔍 Introduction au K-Means

Le K-Means est l'un des algorithmes de clustering les plus populaires.

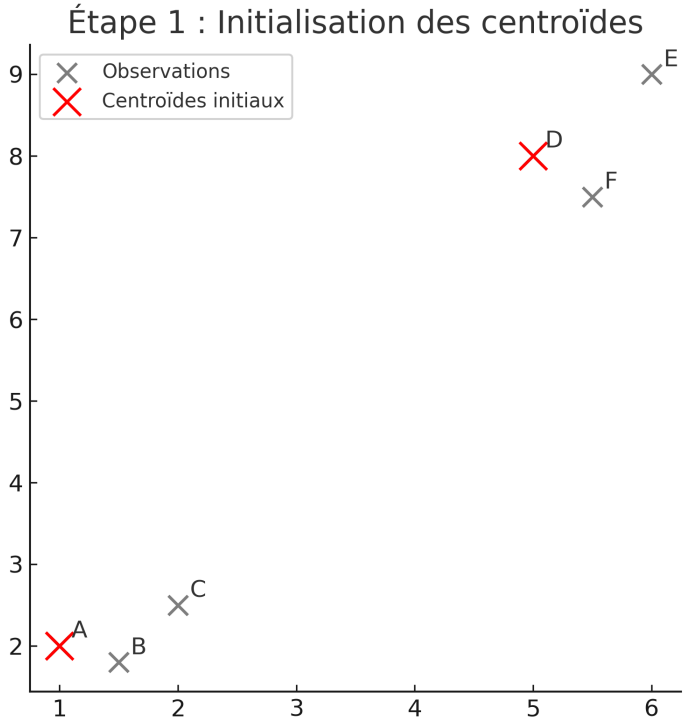
- Il divise les données en **K groupes**
- Chaque groupe a un **centroïde**, représentant son centre
- L'algorithme minimise la distance entre les points et leurs centroïdes
- Basé sur la minimisation des distances entre points et centroïdes
- Utilisé en segmentation, classification et réduction de données
- Fonctionne en itérations successives jusqu'à convergence

L'algorithme du kmeans

1. Positionnement de centroïds C_n dans l'éspace des données de façon aléatoire
2. Calcul de toutes distantes entre l'ensemble des centroïds C_n et les observation x_i:
   - $d(x_i, C_k) = \sqrt{(x_i - C_k)^2}$
3. Associer les donnes x_i aux centroids C_n le plus proches:
   - $x_i \in C_k \quad \text{si} \quad d(x_i, C_k) \leq d(x_i, C_j) \quad \forall j \neq k$
4. Mise à jour des centroids en respectant la formule suivante:
   - $\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$
5. Vérification du **critère d'arrêt** :
   - L'algorithme s'arrête si les centroïdes **ne bougent plus** :
     $||C_k^{(t+1)} - C_k^{(t)}|| < \epsilon$
   - Ou si un **nombre maximal d'itérations** est atteint.

💻 Étape 1 : Initialisation des centroïdes

1. Choisir un nombre de clusters **K**
2. Sélectionner **K centroïdes aléatoires** parmi les observations
3. Définir ces centroïdes comme points initiaux

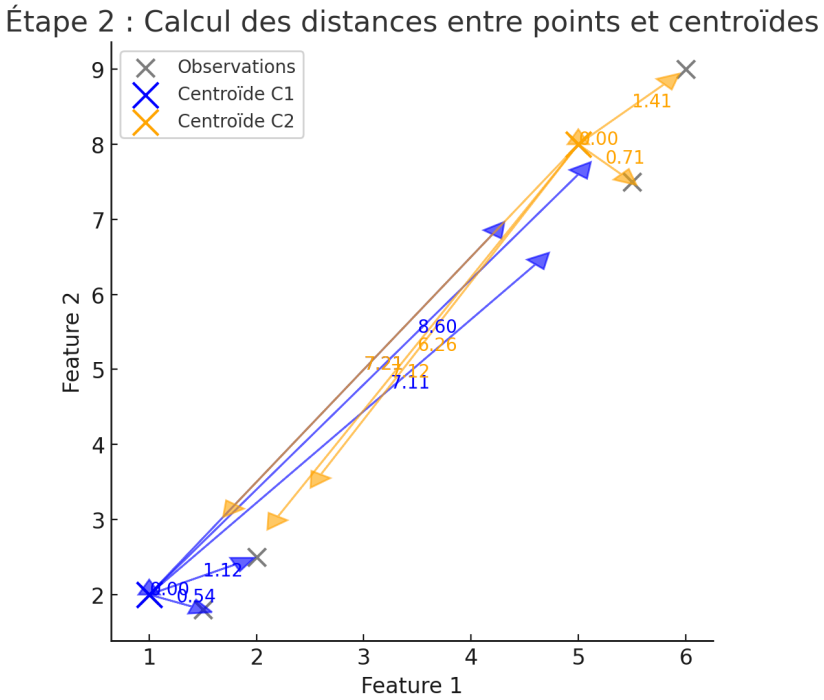


📊 Étape 2 : Calcul des distances

1. Calculer la **distance euclidienne** entre chaque point et chaque centroïde :

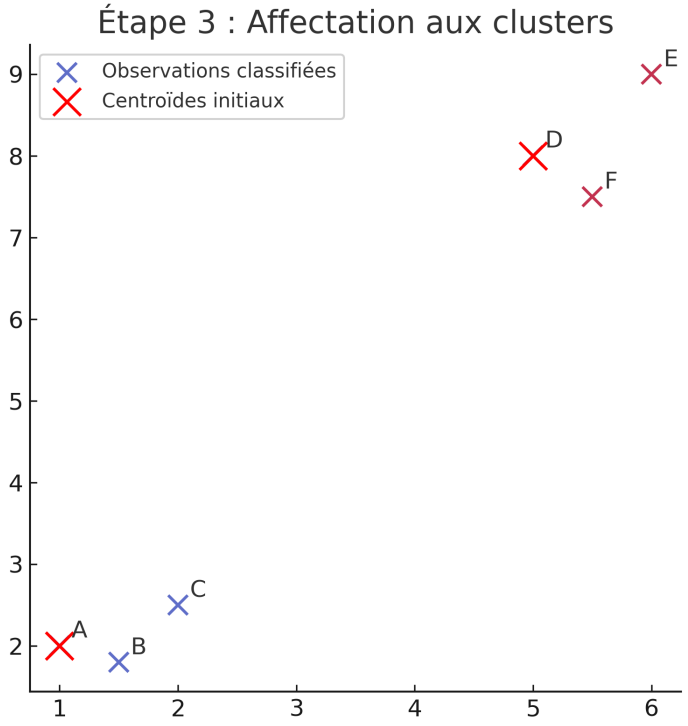
$$d(x_i, C_k) = \sqrt{(x_i - C_k)^2}$$

2. Assigner chaque point au centroïde **le plus proche**



💡 Étape 3 : Affectation aux clusters

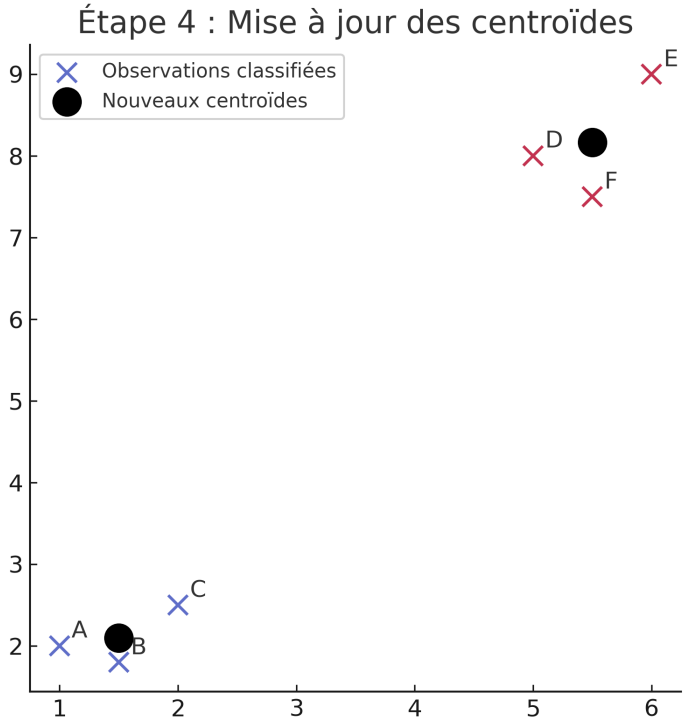
Chaque point est **attribué** au cluster dont il est **le plus proche**.
Cela crée une **première séparation** des données.



📈 Étape 4 : Mise à jour des centroïdes

1. Recalculer les **nouveaux centroïdes** en prenant la **moyenne** des points associés à chaque cluster :

$$C_k^{(new)} = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$



⚠ Étape 5 : Vérification du critère d'arrêt

L'algorithme s'arrête si :

- Les centroïdes **ne bougent plus** :
  $||C_k^{(t+1)} - C_k^{(t)}|| < \epsilon$
- Un **nombre maximum d'itérations** est atteint.

Points importants ⚠

- Le nombre de cluster est un point très important
- Comment mesurer les performance de mon **modèle** ?
- Le kmeans est très sensible aux **outliers** (traité dans la partie suivante)

Le nombre de cluster est un point très important

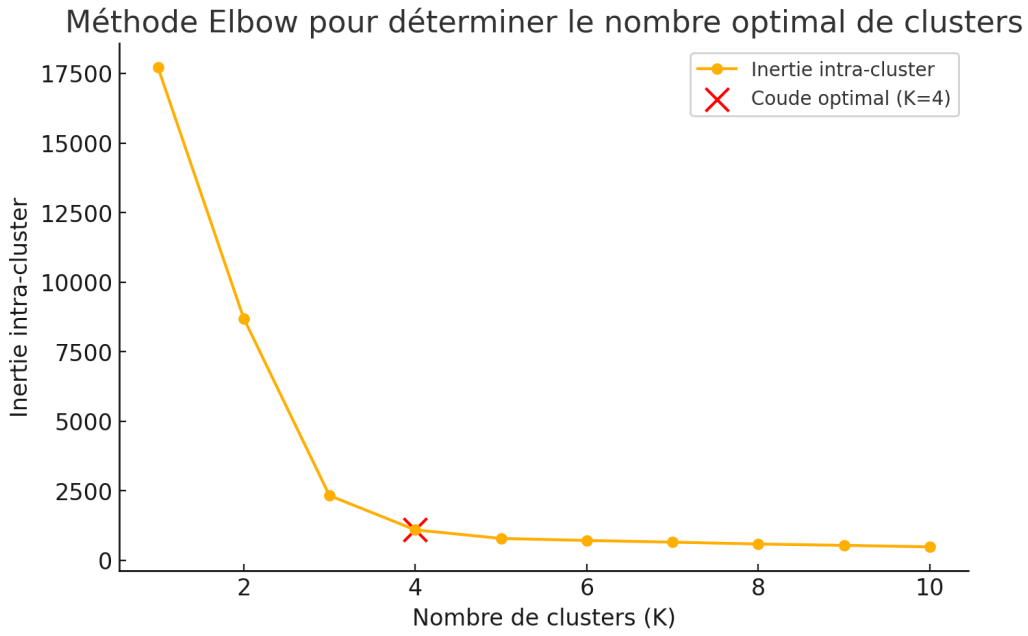
Une méthode nous permet de savoir comment établir notre nombre de clusters initiaux, la méthode **Elbow**.

Le but est simple exécuté plusieurs fois notre algorithme Kmeans avec des clusters allant de 1 à n pour voir l'évolution de W.
Nous pouvons nous arrêter au moment ou W ne bouge plus beaucoup. Impliquant qu'importe le nombre de futur cluster le minimum W n'aura plus de changement significatif.

La méthode elbow

📌 Explication :

- Le point en rouge (K=4) représente le "coude", où l'inertie cesse de diminuer de manière significative.



Comment mesurer les performance de mon modèle ?

1. Le score de silhouette
2. Le WSS

Silhouette : Mesure **la qualité du clustering** en évaluant **la cohésion** d'un cluster et **la séparation** avec les autres.

Formule :

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$ **: Cohésion**
  - Distance moyenne entre un point (i) et tous les autres points de son **propre cluster**.
- $b(i)$ **: Séparation**
  - Distance moyenne entre un point (i) et tous les points du **cluster voisin le plus proche**.

Interprétation du score :

- $S(i) \approx 1$ → Le point est bien dans son cluster.
- $S(i) \approx 0$ → Le point est proche d'un autre cluster.
- $S(i) < 0$ → Le point est probablement mal classé.

Le **SSE (Sum of Squared Errors)** mesure la **dispersion des points autour de leur centroïde**.

Formule :

$$SSE = \sum_{i=1}^{k} \sum_{x_j \in C_i} ||x_j - \mu_i||^2$$

Explication des termes :

- k : Nombre de clusters.
- x_j : Un point dans le cluster.
- C_i : Ensemble des points du cluster i.
- μ_i : Centroïde du cluster i.

Interprétation du score SSE :

SSE faible → Les points sont **proches de leurs centroïdes**
SSE élevé → Les points sont **éloignés de leurs centroïdes**
Problème → Le SSE **diminue toujours quand k augmente**, donc il **ne suffit pas** pour choisir le bon k (méthode Elbow recommandée !).

Ces deux métriques permettent d'évaluer et d'optimiser un modèle K-Means !

Partie 4: Comprendre comment éxploiter des données

- Pré-traitement des données
- Scaling de nos données

Le prétraitement des données est une étape **essentielle** en Machine Learning. Il permet d'améliorer la **qualité** et la **pertinence** des données avant leur utilisation dans un modèle.

Exemple de dataset brut :

Nom	Âge	Salaire	Ville	Score Test	Employé	Date Embauche
Alice	25	35000	Paris	78	Oui	2019-03-15
Bob	38	42000	Lyon	85	Non	2015-07-21
Charlie	NaN	30000	Marseille	65	Oui	2021-01-10
David	50	54000	Paris	90	Non	2010-09-12
Emma	29	NaN	Bordeaux	NaN	Oui	2018-06-30

Ce dataset brut contient plusieurs problèmes nécessitant un prétraitement.

🔍 1. Gestion des Données Manquantes

Détection des valeurs manquantes (`NaN`).
Techniques de traitement :

- Suppression si trop de valeurs manquantes.
- Imputation (moyenne, médiane, mode, prédiction).

Transformation du dataset après imputation :

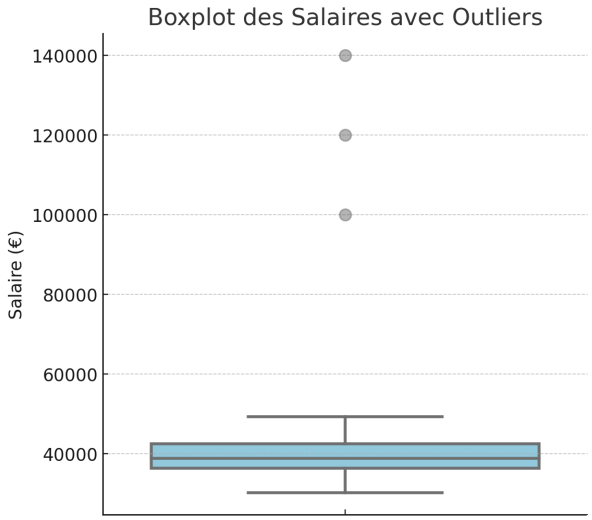
ID	Nom	Âge	Salaire	Ville	Score Test	Employé	Date Embauch
3	Charlie	34	30000	Marseille	65	Oui	2021-01-10
5	Emma	29	42000	Bordeaux	80	Oui	2018-06-30

🚪 2. Détection et Traitement des Outliers

Utilisation d'un boxplot pour détecter les outliers.
Techniques de gestion des valeurs aberrantes :

- Suppression des valeurs extrêmes.
- scaling.

Graphique des outliers (Boxplot sur les salaires) :



💻 3. Normalisation et Standardisation

Utilisation du MinMaxScaler, StandardScaler, RobustScaler.
Objectif : Mettre toutes les variables numériques sur la même échelle.
Transformation des valeurs :

ID	Nom	Âge Standardisé	Salaire Normalisé
1	Alice	-1.2	0.23
2	Bob	0.8	0.56

💻 3.bis Normalisation et Standardisation, comment choisir ?

StandardScaler (Standardisation) : Utilisé lorsque les données suivent une distribution **normale** (gaussienne). La formule mathématique est $X_{scaled} = \frac{X-\mu}{\sigma}$, où μ est la moyenne et σ l'écart-type.

MinMaxScaler (Normalisation) : Idéal lorsque les données doivent être **comprises entre 0 et 1**, particulièrement pour les réseaux neuronaux. La formule est $X_{scaled} = \frac{X-X_{min}}{X_{max}-X_{min}}$.

RobustScaler (Standardisation robuste) : Recommandé lorsque les données contiennent des **outliers** qui pourraient fausser la moyenne et l'écart-type. Utilise la formule $X_{scaled} = \frac{X-Q1}{Q3-Q1}$, où Q1 et Q3 sont les quartiles.

MaxAbsScaler (Normalisation) : Adapté lorsque les données ont des valeurs **positives et négatives** et doivent être **comprises entre -1 et 1**. La formule est $X_{scaled} = \frac{X}{|X_{max}|}$.

💻 3.bis bis Normalisation et Standardisation, pourquoi c'est important ?

Le scaling est crucial en Machine Learning et Deep Learning car :

- Évite la domination d'une feature sur une autre → Une variable avec de grandes valeurs (ex: salaire) peut écraser une autre (ex: âge).
- Accélère la convergence des modèles → Les algorithmes comme Gradient Descent convergent plus vite avec des valeurs bien mises à l'échelle.
- Améliore la précision → Certains modèles (K-Means, SVM, Réseaux de Neurones) sont sensibles à l'échelle des variables.
- Facilite l'interprétation des coefficients → Dans les modèles linéaires, standardiser permet d'avoir des coefficients comparables.

Sans scaling, un modèle peut mal apprendre ou être inefficace !

🚀 4. Encodage des Variables Catégorielles

One-Hot Encoding, Ordinal Encoding, Target Encoding.
Exemple de transformation :

ID	Paris	Lyon	Marseille	Bordeaux
1	1	0	0	0
2	0	1	0	0

🔧 5. Binarisation des Variables

Transformation des variables booléennes en 0 et 1.
Exemple :

ID	Employé (binaire)
1	1
2	0

🏆 6. Sélection et Création de Caractéristiques

Feature Engineering : Création de nouvelles variables pertinentes.
Exemple : Transformation des dates.

ID	Ancienneté (années)
1	5
2	9

Ce processus de prétraitement améliore la qualité des données avant leur utilisation dans un modèle de Machine Learning.

Des questions ?