TP Régression Linéaire

de Boisvilliers christoher

April 1, 2025

TP : Régression Linéaire sur des Données Kaggle

Objectif

Réaliser une régression linéaire à partir d'un dataset Kaggle, évaluer sa performance, interpréter les résultats, et justifier la sélection des variables explicatives.

Bloc 1 : Chargement et exploration des données

Étapes :

1. Télécharger un des datasets proposés ci-dessous.
2. Charger le dataset dans un notebook Jupyter.
3. Afficher les premières lignes du jeu de données.
4. Vérifier les types de données et les valeurs manquantes (one hot encoding, binarisation).
5. Réaliser quelques visualisations exploratoires (pairplot, heatmap, boxplot).

Datasets Kaggle recommandés :

1. Student Performance Dataset
2. Car Price Prediction
3. House Sales in King County, USA
4. Medical Insurance Cost

Libre à vous d'en choisir d'autres.

Bloc 2 : Préparation des données et sélection des variables explicatives

Étapes :

1. Sélectionner la variable cible (Y) et les variables explicatives (X).
2. Standardiser les variables si nécessaire (`StandardScaler ou Robust`) .
3. Calculer le **VIF (Variance Inflation Factor)** pour chaque variable afin de détecter la multicolinéarité.
4. Supprimer les variables avec un VIF > 10 puis recalculer les VIFs après chaque suppression.
5. Réaliser une régression linéaire simple avec `statsmodels`.
6. Interpréter les **p-values** associées aux coefficients des variables :
   - p-value $< 0.05 \rightarrow$ variable significative
   - p-value $\quad 0.05 \rightarrow$ variable potentiellement inutile
7. Conserver uniquement les variables explicatives à la fois non multicolinéaires (VIF bas) et significatives (p-value basse).

Autres éléments importants à vérifier :

- Corrélation forte entre variables explicatives ? (via `df.corr()`)
- Présence de variables catégorielles à encoder ?
- Transformation éventuelle de certaines variables (log, sqrt, etc.) ?

Rappel sur vif et df:

"Le VIF détecte les redondances globales entre variables, tandis que df.corr() ne détecte que des relations binaires."

Outil	Mesure	Type de relation	Pratique courante
`df.corr()`	Corrélation linéaire	Deux à deux	Début d'analyse
VIF	Multicolinéarité globale	Une variable vs. toutes les autres	Validation des variables

Pour les transformations:

Problème	Symptôme	Transformation courante
Relation non-linéaire $X - Y$	Les points ne suivent pas une droite	log(x), sqrt(x), x^2, etc.

Problème	Symptôme	Transformation courante
Présence d'outliers (valeurs extrêmes)	Quelques valeurs très grandes qui tirent la droite	log(x) ou x · pour lisser
Distribution très asymétrique	Histogramme très skewé, pic à gauche/droite	log(x) pour la "normaliser"
Effet multiplicatif au lieu d'additif	Exemple : un revenu x2 fait y x10	log(x) souvent plus pertinent

---

Bloc 3 : Construction du modèle

Étapes :

1. Séparer les données en `X_train` / `X_test`, `y_train` / `y_test`.
2. Créer un premier modèle avec `LinearRegression()` ou `statsmodels.OLS`.
   - Avec l'ensemble des données pré traité et non selectionné
   - Avec l'ensemble des données pré traité et selectionné
3. Créer un deuxième modèle avec `SGDRegressor()`.
   - Avec l'ensemble des données pré traité et non selectionné
   - Avec l'ensemble des données pré traité et selectionné
4. Entraîner le modèle sur les données d'entraînement.

À cette étape vous avez normalement 4 modèles bien stockés.

Bloc 4 : Évaluation du modèle

Métriques à calculer pour chaque modèle :

- R^2 : Coefficient de détermination
- RMSE : Racine de l'erreur quadratique moyenne
- MAE : Erreur absolue moyenne
- Visualiser les **résidus** (distribution et homoscédasticité)

Bloc 5 : Validation de l'approche

Étapes :

1. Vérifier les hypothèses de la régression linéaire :
   - Linéarité
   - Indépendance des résidus
   - Normalité des résidus (QQ plot)
   - Homoscédasticité (résidus aléatoires) > Les résidus doivent être centrés, non structurés, avec une variance constante. Leur analyse permet de détecter des **violations d'hypothèses** du modèle linéaire.
2. Ajouter une **cross-validation** (`cross_val_score`) pour vérifier la robustesse du modèle qui vous a permis d'avoir le meilleur score à l'étape précedente

   La CV ne sert pas à créer le modèle final, mais à estimer sa performance sur des jeux de données variés. Elle permet de valider sa robustesse avant de l'utiliser en production.(Comment mon modèle se comporte sur d'autres jeux de données possibles, issus de la même population)

3. Générer une **learning curve** pour visualiser l'impact de la taille du jeu de données sur la performance. À quel moment je peux arréter mon entrainement ?

Rappel sur les hypothèses fondamentales que doit respecter une régression linéaire

Hypothèse	Description	Vérification possible
1. Linéarité	La relation entre les variables explicatives et la cible est linéaire	Visualiser les résidus ou utiliser `sns.pairplot`, `sns.residplot`
2. Indépendance des erreurs	Les erreurs sont indépendantes les unes des autres	Test de Durbin-Watson, ou vérifier les patterns dans les résidus
3. Homoscédasticité	La variance des erreurs est constante (pas d'effet "entonnoir")	Graphe des résidus vs. prédictions ; `sns.scatterplot(y_pred, residuals)`
4. Normalité des erreurs	Les résidus suivent une distribution normale	Histogramme, courbe de densité, test de Shapiro-Wilk, `qqplot`

Hypothèse	Description	Vérification possible
5. Pas de multicolinéarité excessive	Les variables explicatives ne doivent pas être trop corrélées entre elles	Vérification du VIF (`variance_inflation_factor`)

Optionnel : Over ou Under Fitting

- Est ce que votre modèle overfit ? Underfit ?
- Comment pouvez vous le confirmer ?

Objectif final

À la fin de ce TP, vous devez être capables de : - Construire un modèle de régression robuste à partir de données réelles - Sélectionner intelligemment vos variables explicatives - Expliquer et interpréter les résultats de votre modèle - Diagnostiquer les défauts de votre modèle via les outils statistiques classiques

> Interpréter un modèle linéaire, c'est expliquer le **sens des coefficients** β_i et leur **significativité statistique**.

N'oubliez pas de commenter chaque étape dans votre notebook !